

LAPORAN AKHIR PROYEK

Deep Learning dan Sistem Multimedia

Deteksi Stres Berbasis Ekpresi Wajah Menggunakan CNN dengan Perbandingan Precision dan Quantization



Disusun Oleh:

Nashwa	2C2250004
Fitri Fatimah	2C2230004
Kanaya Dzikra	2C2230015
Amelia Regina	2C2230019

PROGRAM STUDI SAINS DATA

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS KOPERASI INDONESIA

JATINANGOR

2026

DAFTAR ISI

DAFTAR ISI.....	ii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	1
1.3 Tujuan Proyek.....	2
1.4 Batasan dan Asumsi	2
BAB II DASAR TEORI DAN PENELITIAN TERKAIT	3
2.1 Stres dan Ekspresi Wajah	3
2.2 Deep Learning dan Convolutional Neural Network (CNN).....	3
2.3 Dataset FER2013	3
2.4 Precision Reduction dan Quantization	4
2.5 Penelitian Terkait.....	6
BAB III METODOLOGI DAN RANCANGAN SISTEM	7
3.1 Alur Kerja Umum.....	7
3.2 Dataset dan Pra – Preprosesan	8
3.2.1 Sumber Data.....	8
3.2.2 Restrukturisasi Kelas	8
3.2.3 Pipeline Pra – pemrosesan.....	9
3.3 Arsitektur Model CNN	10
3.4 Konfigurasi Training.....	10
3.5 Eksperimen Precision dan Quantization	12
3.6 Rancangan Sistem Multimedia.....	14
BAB IV IMPLEMENTASI DAN HASIL EVALUASI.....	16
4.1 Lingkungan Implementasi	16
4.2 Hasil Preprocessing Dataset	16
4.3 Hasil Pelatihan Model	17
4.4 Hasil Evaluasi Model	19
4.4.1 Metrik Evaluasi.....	19
4.4.2 Classification Report.....	20
4.5 Hasil Eksperimen Precision dan Quantization.....	22
4.6 Implementasi Dashboard Sistem Multimedia.....	27
4.6.1 Fitur Dashboard.....	27
4.6.2 Hasil Pengujian Dashboard	28

BAB V PENGUJIAN DAN EVALUASI SISTEM.....	30
5.1 Hasil Pengujian Sistem	30
5.2 Evaluasi Sistem Multimedia	31
5.3 Analisis Risiko dan Mitigasi	32
5.4 Kelebihan dan Keterbatasan Sistem.....	33
BAB VI PENUTUP	34
6.1 Kesimpulan.....	34
6.2 Saran	35
DAFTAR PUSTAKA	36
LAMPIRAN.....	38

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kesehatan mental menjadi isu penting di era modern karena meningkatnya tekanan akademik, pekerjaan, dan aktivitas sosial. Stres merupakan salah satu kondisi psikologis yang dapat memengaruhi kesehatan mental, produktivitas, konsentrasi, serta kualitas hidup seseorang. Kondisi stres yang tidak terdeteksi dan tidak ditangani secara tepat dapat berkembang menjadi masalah kesehatan yang lebih serius, seperti gangguan kecemasan, depresi, hingga penyakit fisik.

Ekspresi wajah merupakan salah satu bentuk informasi visual yang dapat digunakan untuk memahami kondisi emosional seseorang. Ekspresi seperti marah, takut, sedih, dan jijik dapat diasosiasikan dengan emosi negatif yang berpotensi berkaitan dengan kondisi stres. Sementara itu, ekspresi bahagia, netral, dan terkejut dapat dikelompokkan sebagai kondisi non-stress dalam konteks klasifikasi sederhana.

Perkembangan Artificial Intelligence, khususnya Deep Learning, memungkinkan analisis ekspresi wajah dilakukan secara otomatis menggunakan model klasifikasi citra. Convolutional Neural Network (CNN) merupakan arsitektur yang paling banyak digunakan dalam pengolahan citra karena kemampuannya mengekstraksi fitur visual secara otomatis melalui convolution layer dan pooling layer. Namun, model deep learning umumnya memiliki ukuran yang cukup besar dan membutuhkan komputasi tinggi, sehingga menjadi tantangan tersendiri dalam implementasi pada sistem realtime.

Berdasarkan latar belakang tersebut, proyek ini dirancang untuk membangun sistem deteksi stres berbasis ekspresi wajah menggunakan CNN, disertai analisis efisiensi deployment melalui teknik precision reduction dan quantization, serta implementasi dalam bentuk dashboard multimedia interaktif yang dapat digunakan secara realtime.

1.2 Rumusan Masalah

Rumusan masalah dalam proyek ini adalah sebagai berikut:

1. Bagaimana merancang model CNN untuk mendeteksi stres berbasis ekspresi wajah menggunakan dataset FER2013 yang direstrukturisasi menjadi kelas stress dan non_stress?
2. Bagaimana melakukan preprocessing, augmentasi, dan pencegahan data leakage agar data citra wajah siap digunakan untuk proses training dan evaluasi model?
3. Bagaimana membandingkan performa model CNN pada varian FP32, FP16, dan QINT8 berdasarkan accuracy, ukuran model, dan latency inferensi?

4. Bagaimana mengintegrasikan model CNN ke dalam sistem multimedia berupa dashboard realtime berbasis upload gambar dan webcam untuk menampilkan hasil prediksi stress atau non_stress?

1.3 Tujuan Proyek

Tujuan utama proyek ini adalah:

1. Merancang dan melatih model CNN (EmotionCNNDeepFC) untuk klasifikasi ekspresi wajah menjadi kelas stress dan non_stress dengan validation accuracy minimal 80%.
2. Melakukan preprocessing dataset FER2013 secara komprehensif, mencakup restrukturisasi kelas, pengecekan data leakage, augmentasi data, dan normalisasi citra.
3. Membandingkan performa model pada format FP32, FP16, dan QINT8 berdasarkan accuracy, ukuran model, dan latency inferensi.
4. Merancang simulasi low-bit precision (FLOAT8, FLOAT4, QINT4) sebagai analisis potensi deployment masa depan.
5. Membangun dashboard multimedia realtime yang mendukung input upload gambar dan webcam, serta menampilkan hasil prediksi secara interaktif.

1.4 Batasan dan Asumsi

Proyek ini memiliki batasan dan asumsi sebagai berikut:

1. Dataset yang digunakan adalah FER2013, yaitu dataset ekspresi wajah grayscale berukuran 48x48 piksel yang tersedia secara publik di Kaggle.
2. Model dibatasi pada custom CNN (EmotionCNNDeepFC) dengan binary classification output (stress dan non_stress).
3. Eksperimen precision dibatasi pada FP32 (baseline), FP16 (half-precision GPU), dan QINT8 (dynamic quantization CPU).
4. Simulasi FLOAT8, FLOAT4, dan QINT4 hanya digunakan untuk estimasi ukuran model, bukan sebagai native quantization penuh.
5. Sistem dashboard bersifat prototype untuk kebutuhan pembelajaran dan demonstrasi, bukan sebagai alat diagnosis medis.
6. Pengelompokan emosi ke dalam kelas stress dan non_stress bersifat asumsi berbasis ekspresi, bukan diagnosis psikologis klinis.

BAB II

DASAR TEORI DAN PENELITIAN TERKAIT

2.1 Stres dan Ekspresi Wajah

Stres merupakan respons fisik maupun psikologis yang muncul ketika seseorang menghadapi tekanan atau tuntutan yang dianggap melebihi kemampuannya. Kondisi ini dapat memengaruhi kesehatan mental, produktivitas, konsentrasi, serta kualitas hidup seseorang secara signifikan.

Dalam berbagai penelitian psikologi, ekspresi wajah sering digunakan sebagai indikator nonverbal untuk menggambarkan kondisi emosional seseorang. Ekspresi seperti marah (angry), takut (fear), sedih (sad), dan jijik (disgust) dapat diasosiasikan dengan kondisi emosi negatif yang berhubungan dengan stres. Sementara ekspresi bahagia (happy), netral (neutral), dan terkejut (surprise) lebih cenderung diasosiasikan dengan kondisi non-stress.

2.2 Deep Learning dan Convolutional Neural Network (CNN)

Deep Learning merupakan cabang dari Machine Learning yang menggunakan jaringan saraf tiruan berlapis-lapis untuk mempelajari pola yang kompleks dari data. Keunggulan utama Deep Learning terletak pada kemampuannya melakukan ekstraksi fitur secara otomatis tanpa memerlukan proses rekayasa fitur secara manual.

Convolutional Neural Network (CNN) merupakan arsitektur Deep Learning yang paling banyak digunakan dalam pengolahan citra. CNN dirancang untuk mengekstraksi informasi visual melalui proses convolution, activation function, pooling, dan fully connected layer. Struktur ini memungkinkan CNN mengenali pola-pola penting seperti tepi, tekstur, bentuk, hingga karakteristik visual yang lebih kompleks pada citra wajah.

2.3 Dataset FER2013

FER2013 (Facial Expression Recognition 2013) adalah dataset standar pada bidang pengenalan ekspresi wajah yang dikembangkan oleh Goodfellow et al. Dataset ini terdiri atas ribuan citra wajah grayscale berukuran 48x48 piksel yang telah diberi label tujuh kelas emosi, yaitu angry, disgust, fear, happy, sad, surprise, dan neutral.

Pada proyek ini, ketujuh kelas tersebut direstrukturisasi menjadi dua kelas utama. Kelas stress dibentuk dari emosi angry, disgust, fear, dan sad, sedangkan kelas non_stress terdiri atas happy, surprise, dan neutral. Pendekatan ini memfokuskan model pada deteksi indikasi stres berbasis ekspresi wajah.

2.4 Precision Reduction dan Quantization

Precision reduction dan quantization merupakan salah satu teknik optimasi yang banyak digunakan pada model deep learning untuk meningkatkan efisiensi model pada tahap implementasi (deployment). Teknik ini dilakukan dengan mengurangi jumlah bit yang digunakan dalam merepresentasikan parameter model sehingga ukuran model menjadi lebih kecil, penggunaan memori berkurang, serta proses inferensi dapat berjalan lebih cepat. Meskipun demikian, penerapan quantization harus tetap mempertimbangkan performa model agar penurunan akurasi yang terjadi tidak terlalu besar.

Pada penelitian ini, dataset yang digunakan adalah FER2013 (Facial Expression Recognition 2013) yang terdiri atas citra wajah grayscale. Seluruh citra pada dataset tersebut memiliki representasi piksel 8-bit (uint8) dengan rentang nilai intensitas antara 0 sampai 255. Representasi 8-bit tersebut merupakan format penyimpanan citra yang umum digunakan sehingga ukuran data relatif kecil dan mudah diproses pada tahap awal pengolahan data.

Meskipun dataset asli menggunakan format 8-bit, data tersebut tidak langsung digunakan dalam bentuk tersebut selama proses pelatihan model. Sebelum dimasukkan ke dalam arsitektur Convolutional Neural Network (CNN), seluruh citra terlebih dahulu melalui proses preprocessing menggunakan transformasi `ToTensor()` dan `Normalize()` yang disediakan oleh framework PyTorch. Transformasi `ToTensor()` mengubah data citra dari format NumPy array bertipe uint8 menjadi tensor bertipe Floating Point 32-bit (FP32) dengan rentang nilai antara 0 dan 1. Selanjutnya, transformasi `Normalize()` melakukan normalisasi terhadap nilai piksel sehingga distribusi data menjadi lebih stabil selama proses pelatihan.

Penggunaan format FP32 pada tahap pelatihan bukan merupakan keputusan yang ditentukan oleh peneliti, melainkan merupakan mekanisme standar yang digunakan oleh PyTorch dalam melakukan proses pembelajaran model deep learning. Format FP32 dipilih karena memiliki tingkat presisi yang tinggi sehingga proses perhitungan gradien (backpropagation) dapat dilakukan dengan lebih stabil. Selain itu, pembaruan bobot (weight update) pada setiap iterasi pelatihan menjadi lebih akurat sehingga proses optimasi model dapat berjalan dengan baik. Oleh karena itu, seluruh proses training pada penelitian ini dilakukan menggunakan model dengan representasi FP32.


Setelah proses pelatihan selesai dan diperoleh model terbaik, barulah dilakukan proses precision reduction dan quantization. Tahap ini dilakukan bukan untuk mengembalikan representasi data menjadi 8-bit seperti dataset awal, melainkan untuk mengurangi presisi parameter model yang telah selesai dilatih agar proses inferensi menjadi lebih efisien. Pada tahap inferensi model tidak lagi melakukan proses perhitungan gradien sehingga penggunaan presisi yang lebih rendah masih mampu mempertahankan performa model dengan penurunan akurasi yang relatif kecil.

Penelitian ini menggunakan tiga jenis format presisi utama, yaitu FP32, FP16, dan QINT8. FP32 digunakan sebagai model dasar (baseline model) karena merupakan hasil langsung dari proses pelatihan. Selanjutnya model tersebut dikonversi ke dalam format FP16 (Half Precision) untuk mengurangi penggunaan memori ketika dijalankan pada perangkat yang mendukung komputasi half precision, khususnya GPU. Selain itu diterapkan pula Dynamic Quantization menggunakan format QINT8 yang mengubah parameter pada layer tertentu menjadi bilangan integer 8-bit sehingga ukuran model menjadi lebih kecil dan proses inferensi pada CPU dapat berlangsung lebih efisien.

Selain eksperimen utama tersebut, penelitian ini juga melakukan percobaan menggunakan format FP8 native melalui tipe data `torch.float8_e4m3fn`. Berdasarkan hasil implementasi pada notebook, proses konversi parameter model ke format FP8 berhasil dilakukan. Akan tetapi, pada saat model digunakan untuk melakukan inferensi muncul pesan kesalahan `getCudnnDataTypeFromScalarType() not supported`. Hal tersebut menunjukkan bahwa framework PyTorch beserta pustaka cuDNN yang digunakan masih memiliki keterbatasan dalam mendukung inferensi CNN menggunakan format FP8. Oleh karena itu, format FP8 native tidak dapat digunakan sebagai bagian dari eksperimen utama pada penelitian ini.

Penelitian ini juga menyertakan simulasi menggunakan format FLOAT8, FLOAT4, dan QINT4 sebagai analisis tambahan. Berbeda dengan FP16 dan QINT8 yang benar-benar diterapkan pada model hasil pelatihan, ketiga format tersebut tidak menggunakan model yang telah dikuantisasi secara nyata. Berdasarkan implementasi pada notebook, model yang digunakan untuk simulasi tetap merupakan model FP32, sedangkan ukuran model dihitung menggunakan estimasi berdasarkan rasio jumlah bit terhadap ukuran model FP32. Oleh karena itu, nilai akurasi dan latency yang diperoleh pada simulasi FLOAT8, FLOAT4, dan QINT4 berasal dari hasil pengujian model FP32, sedangkan ukuran model merupakan hasil estimasi secara teoritis. Simulasi ini hanya digunakan untuk memberikan gambaran mengenai potensi efisiensi apabila dukungan terhadap format presisi rendah telah tersedia secara penuh pada framework maupun perangkat keras di masa mendatang.

Berdasarkan tahapan tersebut, alur penggunaan representasi data pada penelitian ini dimulai dari citra FER2013 yang disimpan dalam format 8-bit, kemudian diubah menjadi tensor FP32 selama proses pelatihan model, dan setelah model terbaik diperoleh dilakukan eksperimen quantization menggunakan FP16 dan QINT8. Dengan demikian, proses quantization dilakukan pada model yang telah selesai dilatih (post-training quantization), bukan pada data citra yang digunakan sebagai masukan model.



Berdasarkan Gambar dapat dilihat bahwa proses quantization tidak dilakukan secara langsung terhadap data citra, melainkan terhadap model yang telah selesai dilatih menggunakan format FP32. Tahapan tersebut menunjukkan bahwa representasi 8-bit pada dataset hanya digunakan sebagai format penyimpanan citra, sedangkan selama proses pelatihan seluruh data telah dikonversi menjadi tensor FP32 sesuai mekanisme PyTorch. Setelah model terbaik diperoleh, dilakukan eksperimen menggunakan beberapa format presisi yang lebih rendah untuk mengetahui pengaruhnya terhadap efisiensi model tanpa mengurangi performa klasifikasi secara signifikan.

2.5 Penelitian Terkait

Beberapa penelitian terdahulu menjadi landasan dalam pengembangan proyek ini. Young et al. (2021) menunjukkan bahwa quantization mampu mengurangi ukuran model CNN secara signifikan dengan penurunan akurasi yang relatif kecil. Harjanto et al. (2024) membuktikan bahwa pruning dan quantization dapat meningkatkan efisiensi inferensi pada perangkat dengan sumber daya terbatas. Khairuddin dan Chen (2021) mendemonstrasikan bahwa CNN mampu mencapai performa tinggi pada dataset FER2013.

Berbagai penelitian mengenai facial expression recognition juga menunjukkan keberhasilan CNN dalam mengenali ekspresi wajah manusia dengan tingkat akurasi yang baik. Perbedaan proyek ini dengan penelitian sebelumnya terletak pada integrasi antara klasifikasi stress berbasis ekspresi wajah, analisis perbandingan precision model FP32, FP16, dan QINT8, serta implementasi dashboard multimedia interaktif berbasis upload gambar dan webcam realtime.

BAB III

METODOLOGI DAN RANCANGAN SISTEM

3.1 Alur Kerja Umum



Gambar 3.1 menunjukkan alur pelaksanaan proyek yang dilakukan secara bertahap mulai dari identifikasi masalah hingga implementasi sistem. Tahap pertama diawali dengan studi literatur dan definisi masalah melalui kajian mengenai Convolutional Neural Network (CNN), dataset FER2013, facial expression recognition, precision format, quantization, serta sistem multimedia realtime. Pada tahap ini juga ditentukan fokus penelitian yaitu mendeteksi indikasi stres berdasarkan ekspresi wajah.

Tahap berikutnya adalah spesifikasi kebutuhan dan perancangan solusi, yang mencakup penentuan kebutuhan sistem seperti model klasifikasi berbasis CNN untuk membedakan kelas *stress* dan *non_stress*, metode evaluasi model, perbandingan berbagai format presisi seperti FP32, FP16, dan QINT8, serta pengembangan dashboard realtime menggunakan fitur unggah gambar dan webcam.

Selanjutnya dilakukan implementasi model baseline menggunakan CNN dengan input citra grayscale berukuran 48×48 piksel menggunakan format FP32 sebagai acuan utama. Setelah model dasar berhasil dibangun, dilakukan beberapa iterasi peningkatan melalui preprocessing data, augmentasi, tuning parameter model, penerapan early stopping, serta optimasi deployment menggunakan teknik quantization dan precision reduction.

Pada tahap pengujian dan evaluasi, performa model dianalisis menggunakan berbagai metrik seperti accuracy, precision, recall, F1-score, confusion matrix, ROC-AUC, ukuran model, dan latency inferensi. Selain itu, dashboard juga diuji menggunakan skenario prediksi melalui unggah gambar maupun webcam secara realtime.

Tahap terakhir adalah analisis hasil dan dokumentasi, yaitu dengan mengevaluasi trade-off antara akurasi, ukuran model, dan kecepatan inferensi. Seluruh hasil eksperimen kemudian

didokumentasikan dalam bentuk laporan penelitian, notebook eksperimen, visualisasi evaluasi, serta implementasi dashboard sebagai demonstrasi akhir dari sistem yang dikembangkan.

3.2 Dataset dan Pra – Premposesan

3.2.1 Sumber Data

Dataset yang digunakan dalam penelitian ini adalah FER2013 (Facial Expression Recognition 2013) yang tersedia secara publik melalui platform Kaggle. Dataset ini merupakan salah satu dataset benchmark yang paling banyak digunakan dalam penelitian pengenalan ekspresi wajah (Facial Expression Recognition/FER). FER2013 terdiri atas citra wajah grayscale dengan resolusi 48×48 piksel yang merepresentasikan tujuh kategori emosi, yaitu angry, disgust, fear, happy, sad, surprise, dan neutral.

Dataset FER2013 dipilih karena memiliki jumlah data yang relatif besar, variasi ekspresi wajah yang beragam, serta telah banyak digunakan dalam penelitian deep learning sehingga memungkinkan dilakukan perbandingan hasil dengan penelitian terdahulu. Selain itu, penggunaan citra grayscale berukuran kecil juga mendukung efisiensi proses komputasi dan pelatihan model Convolutional Neural Network (CNN).

Pada proyek ini, struktur dataset yang telah tersedia digunakan secara langsung, yaitu terdiri atas folder train dan validation, sehingga pembagian data mengikuti struktur bawaan dataset. Pendekatan ini dipilih untuk menjaga konsistensi pembagian data serta meminimalkan potensi terjadinya data leakage antara data pelatihan dan data validasi.

Sebelum digunakan pada proses pelatihan model, dataset terlebih dahulu melalui tahap pemeriksaan struktur folder, verifikasi jumlah data pada setiap kelas, serta pengecekan duplikasi menggunakan metode hashing untuk memastikan kualitas dan validitas data yang digunakan dalam eksperimen. Selanjutnya, ketujuh kelas emosi tersebut direstrukturasikan menjadi dua kategori utama, yaitu stress yang terdiri atas emosi angry, disgust, fear, dan sad, serta non-stress yang terdiri atas emosi happy, surprise, dan neutral sesuai dengan tujuan penelitian untuk melakukan deteksi indikasi stres berbasis ekspresi wajah.

3.2.2 Restrukturisasi Kelas

Dataset FER2013 yang semula terdiri atas tujuh kelas emosi direstrukturasikan menjadi dua kelas utama, yaitu stress dan non_stress, sesuai dengan tujuan penelitian untuk melakukan klasifikasi biner (binary classification). Pengelompokan ini dilakukan berdasarkan kecenderungan hubungan antara ekspresi emosi dan kondisi psikologis yang berkaitan dengan stres.


Adapun pembagian kelas dilakukan sebagai berikut:

- Kelas stress: angry, disgust, fear, dan sad
- Kelas non_stress: happy, surprise, dan neutral

Emosi angry, disgust, fear, dan sad dikelompokkan ke dalam kelas stress karena merupakan emosi negatif yang dalam berbagai penelitian psikologi dan affective computing sering dikaitkan dengan kondisi tekanan psikologis, ketegangan emosional, serta respons stres. Sementara itu, emosi happy, surprise, dan neutral dikelompokkan ke dalam kelas non_stress karena cenderung tidak secara langsung merepresentasikan kondisi stres yang berkepanjangan.

Restrukturisasi ini dilakukan untuk menyederhanakan permasalahan klasifikasi dari tujuh kelas menjadi dua kelas, sehingga model CNN dapat lebih fokus dalam mempelajari pola ekspresi wajah yang mengindikasikan adanya stres atau non-stres. Selain itu, pendekatan binary classification dipilih karena lebih sesuai dengan tujuan utama penelitian, yaitu mendeteksi indikasi stres berbasis ekspresi wajah, bukan melakukan pengenalan emosi secara detail.

3.2.3 Pipeline Pra – pemrosesan



Gambar 3.x menunjukkan tahapan pra-pemrosesan yang dilakukan sebelum data digunakan pada proses pelatihan model CNN. Proses diawali dengan pengecekan data duplikat menggunakan nama file dan hashing MD5 untuk mencegah terjadinya data leakage antara data training dan validation. Selanjutnya, citra dikonversi menjadi grayscale untuk menjaga konsistensi format input dan mengurangi kompleksitas komputasi. Setelah itu, ukuran gambar disesuaikan menjadi 48×48 piksel sesuai dengan spesifikasi input model. Nilai piksel kemudian dinormalisasi ke rentang 0 hingga 1 untuk meningkatkan stabilitas proses pelatihan, sebelum akhirnya dikonversi ke dalam format tensor agar dapat diproses oleh PyTorch. Pada data training juga diterapkan teknik augmentasi berupa random horizontal flip, random rotation, dan random affine transformation untuk meningkatkan variasi data dan mengurangi risiko overfitting.

3.3 Arsitektur Model CNN



Gambar 3.x memperlihatkan arsitektur model CNN yang digunakan pada penelitian ini, yaitu EmotionCNNDeepFC yang dirancang khusus untuk klasifikasi citra wajah grayscale berukuran 48×48 piksel. Model diawali dengan beberapa convolution layer yang berfungsi untuk mengekstraksi fitur visual dari citra wajah, seperti tepi, tekstur, dan pola ekspresi.

Setiap convolution layer diikuti oleh batch normalization dan fungsi aktivasi ReLU untuk menjaga stabilitas pelatihan serta memperkenalkan non-linearitas pada model. Selanjutnya, max pooling digunakan untuk mengurangi dimensi feature map sambil mempertahankan informasi penting yang telah dipelajari. Untuk mengurangi risiko overfitting, diterapkan pula dropout pada bagian fully connected layer. Pada tahap akhir, model menghasilkan output berupa probabilitas untuk dua kelas, yaitu stress dan non_stress, beserta confidence score dari hasil prediksi yang diberikan.

3.4 Konfigurasi Training

Setelah proses preprocessing selesai dilakukan, tahap berikutnya adalah proses pelatihan (training) model Convolutional Neural Network (CNN). Tujuan dari proses pelatihan ini adalah memperoleh model yang mampu mengenali pola ekspresi wajah dan mengklasifikasikannya ke dalam dua kelas, yaitu stress dan non-stress. Seluruh proses pelatihan dilakukan menggunakan framework PyTorch dengan memanfaatkan kemampuan komputasi GPU sehingga proses training dapat berlangsung lebih cepat dibandingkan menggunakan CPU.

Selama proses pelatihan, seluruh data citra yang sebelumnya telah melalui proses preprocessing berada dalam format Floating Point 32-bit (FP32). Penggunaan format FP32 merupakan standar bawaan PyTorch karena proses pelatihan model deep learning memerlukan perhitungan gradien (gradient computation) dan pembaruan bobot (weight update) yang membutuhkan tingkat presisi tinggi. Dengan menggunakan FP32, proses optimasi model menjadi lebih stabil sehingga risiko kesalahan akibat pembulatan nilai (rounding error) dapat diminimalkan.

Fungsi loss yang digunakan pada penelitian ini adalah CrossEntropyLoss, karena sesuai untuk permasalahan klasifikasi. Fungsi ini menghitung selisih antara hasil prediksi model dengan label sebenarnya sehingga dapat digunakan sebagai dasar dalam memperbarui parameter model pada setiap iterasi pelatihan. Semakin kecil nilai loss yang dihasilkan, maka semakin baik kemampuan model dalam mempelajari pola dari data pelatihan.

Optimasi parameter dilakukan menggunakan AdamW Optimizer dengan learning rate awal sebesar 0,001. Optimizer AdamW dipilih karena mampu memberikan proses konvergensi yang lebih stabil dibandingkan metode optimasi konvensional serta memiliki mekanisme weight decay yang membantu mengurangi risiko overfitting. Selain itu digunakan pula ReduceLROnPlateau Scheduler yang secara otomatis menurunkan nilai learning rate apabila performa model pada data validasi tidak mengalami peningkatan dalam beberapa epoch tertentu. Penggunaan scheduler ini bertujuan agar proses pembelajaran tetap optimal ketika model mulai mendekati kondisi konvergen.

Konfigurasi pelatihan yang digunakan pada penelitian ini dapat dilihat pada Tabel 3.1.

Parameter	Nilai
Framework	PyTorch
Device Training	GPU
Tipe Data Training	Floating Point 32-bit (FP32)
Optimizer	AdamW
Learning Rate	0,001
Scheduler	ReduceLROnPlateau
Loss Function	CrossEntropyLoss
Batch Size	64
Epoch Maksimum	80
Early Stopping	Patience = 10
Best Checkpoint	Epoch ke-75
Validation Accuracy Terbaik	84,97%

Berdasarkan konfigurasi tersebut, model dirancang untuk menjalankan proses pelatihan hingga 80 epoch. Selain itu diterapkan mekanisme early stopping dengan nilai patience sebanyak 10 epoch. Mekanisme ini berfungsi untuk menghentikan proses pelatihan apabila model tidak lagi menunjukkan peningkatan performa pada data validasi selama beberapa epoch berturut-turut. Tujuan penerapan early stopping adalah mengurangi waktu komputasi sekaligus mencegah terjadinya overfitting.

Akan tetapi, berdasarkan hasil pelatihan pada notebook, mekanisme early stopping tidak pernah terpicu. Hal ini disebabkan karena nilai validation accuracy masih mengalami peningkatan meskipun hanya dalam jumlah yang relatif kecil pada beberapa epoch. Setiap kali terjadi peningkatan tersebut, penghitung patience akan kembali ke kondisi awal sehingga proses pelatihan tetap dilanjutkan hingga mencapai jumlah maksimum, yaitu 80 epoch.

Meskipun pelatihan berlangsung hingga epoch ke-80, model terbaik (best checkpoint) tidak diperoleh pada epoch terakhir. Berdasarkan hasil evaluasi selama proses training, model dengan performa terbaik diperoleh pada epoch ke-75 dengan nilai validation accuracy sebesar 84,97%. Setelah epoch tersebut tidak terjadi peningkatan nilai validation accuracy yang melebihi hasil sebelumnya, sehingga sistem tetap menyimpan parameter model pada epoch ke-75 sebagai model terbaik. Model inilah yang kemudian digunakan pada seluruh proses evaluasi dan eksperimen quantization pada tahap berikutnya.

Kondisi tersebut menunjukkan bahwa model telah mencapai performa yang relatif stabil sebelum proses pelatihan berakhir. Walaupun pelatihan tetap berlangsung hingga epoch ke-80, proses tersebut dilakukan untuk memastikan tidak ada peningkatan performa yang lebih baik pada epoch berikutnya. Dengan demikian, penggunaan model hasil checkpoint pada epoch ke-75 dinilai lebih representatif dibandingkan menggunakan model pada epoch terakhir.

3.5 Eksperimen Precision dan Quantization

Setelah proses pelatihan model selesai dilakukan dan diperoleh model terbaik pada epoch ke-75, penelitian dilanjutkan dengan tahap precision reduction dan quantization. Tahap ini bertujuan untuk mengetahui pengaruh perubahan representasi parameter model terhadap ukuran model, penggunaan memori, waktu inferensi (latency), serta akurasi klasifikasi. Berbeda dengan proses pelatihan yang memerlukan presisi tinggi, proses inferensi tidak lagi membutuhkan perhitungan gradien sehingga model dapat dijalankan menggunakan presisi yang lebih rendah untuk meningkatkan efisiensi komputasi.

Pada penelitian ini, model hasil pelatihan menggunakan format Floating Point 32-bit (FP32) dijadikan sebagai baseline model. Model tersebut kemudian digunakan sebagai acuan untuk seluruh eksperimen quantization. Seluruh proses pelatihan dilakukan menggunakan format FP32 karena PyTorch secara default menggunakan representasi tersebut dalam proses pembelajaran model. Setelah model selesai dilatih dan parameter terbaik diperoleh, proses quantization dilakukan tanpa mengubah proses pelatihan yang telah dilakukan sebelumnya (post-training quantization).

Variasi format presisi yang digunakan dalam penelitian ini meliputi FP32, FP16, dan QINT8. Ketiga format tersebut dipilih karena telah didukung oleh framework PyTorch dan dapat diterapkan secara langsung pada model hasil pelatihan. Selain itu dilakukan pula eksperimen terhadap format FP8 serta simulasi FLOAT8, FLOAT4, dan QINT4 sebagai analisis tambahan

untuk melihat potensi efisiensi apabila teknologi tersebut telah didukung secara penuh pada framework maupun perangkat keras.

1. Model FP32 (Baseline)

Model FP32 merupakan model hasil pelatihan yang digunakan sebagai acuan dalam seluruh proses evaluasi. Seluruh parameter model disimpan menggunakan representasi Floating Point 32-bit sehingga memiliki tingkat presisi yang tinggi. Model ini digunakan sebagai pembandingan utama untuk mengevaluasi perubahan performa setelah dilakukan proses quantization ke format presisi yang lebih rendah. Selain menghasilkan akurasi terbaik, model FP32 juga menjadi dasar dalam perhitungan estimasi ukuran model pada eksperimen simulasi FLOAT8, FLOAT4, dan QINT4.

2. Model FP16 (Half Precision)

Setelah model FP32 diperoleh, dilakukan konversi parameter model ke dalam format Floating Point 16-bit (FP16). Proses ini dilakukan setelah pelatihan selesai sehingga tidak memengaruhi proses pembelajaran model. Penggunaan FP16 bertujuan untuk mengurangi penggunaan memori serta meningkatkan efisiensi komputasi ketika model dijalankan pada perangkat yang mendukung operasi half precision, khususnya GPU.

Berdasarkan implementasi pada notebook, ukuran model FP16 dihitung berdasarkan rasio jumlah bit terhadap model FP32. Oleh karena itu, ukuran model FP16 yang ditampilkan pada hasil penelitian merupakan hasil estimasi dari ukuran model FP32. Meskipun menggunakan presisi yang lebih rendah, model FP16 tetap mampu mempertahankan performa klasifikasi yang hampir sama dengan model FP32 sehingga dapat menjadi alternatif untuk proses deployment pada perangkat dengan dukungan komputasi FP16.

3. Model QINT8 (Dynamic Quantization)

Selain FP16, penelitian ini juga menerapkan teknik Dynamic Quantization menggunakan format QINT8. Berbeda dengan FP16 yang masih menggunakan representasi floating point, QINT8 mengubah parameter pada layer tertentu menjadi bilangan integer 8-bit. Implementasi ini bertujuan untuk mengurangi ukuran model sekaligus meningkatkan efisiensi inferensi pada perangkat berbasis CPU.

Berdasarkan hasil pengujian, model QINT8 mampu mempertahankan performa klasifikasi dengan penurunan akurasi yang sangat kecil dibandingkan model FP32. Hal ini menunjukkan bahwa proses quantization berhasil meningkatkan efisiensi model tanpa memberikan pengaruh yang signifikan terhadap kemampuan klasifikasi ekspresi wajah.

4. Eksperimen FP8 Native

Selain FP16 dan QINT8, penelitian ini juga melakukan percobaan menggunakan format FP8 native melalui tipe data `torch.float8_e4m3fn`. Tujuan dari eksperimen ini adalah mengetahui apakah model CNN dapat dijalankan menggunakan representasi floating point 8-bit secara langsung pada framework PyTorch.

Berdasarkan implementasi pada notebook, proses konversi parameter model ke format FP8 berhasil dilakukan. Namun, ketika model digunakan untuk melakukan inferensi muncul pesan kesalahan `getCudnnDataTypeFromScalarType() not supported`. Kesalahan tersebut menunjukkan bahwa versi framework PyTorch maupun pustaka cuDNN yang digunakan belum mendukung inferensi CNN menggunakan format FP8 secara penuh.

Oleh karena itu, eksperimen FP8 native tidak dapat digunakan sebagai bagian dari evaluasi utama penelitian. Hasil percobaan ini justru menunjukkan bahwa implementasi quantization dengan presisi yang sangat rendah masih memiliki keterbatasan dukungan pada perangkat lunak maupun perangkat keras yang digunakan.

5. Simulasi FLOAT8, FLOAT4, dan QINT4

Selain eksperimen quantization yang benar-benar diterapkan pada model, penelitian ini juga melakukan simulasi terhadap format FLOAT8, FLOAT4, dan QINT4. Simulasi ini bertujuan untuk memberikan gambaran mengenai potensi pengurangan ukuran model apabila teknologi quantization dengan presisi yang lebih rendah telah tersedia secara penuh.

Berdasarkan implementasi pada notebook, model yang digunakan pada simulasi tersebut tetap merupakan model FP32. Dengan demikian, proses inferensi tidak dilakukan menggunakan model FLOAT8, FLOAT4, maupun QINT4 yang sebenarnya. Ukuran model dihitung menggunakan estimasi berdasarkan rasio jumlah bit terhadap ukuran model FP32, sedangkan nilai akurasi dan waktu inferensi tetap berasal dari hasil pengujian model FP32.

Oleh karena itu, hasil simulasi FLOAT8, FLOAT4, dan QINT4 tidak dapat diinterpretasikan sebagai hasil quantization yang sesungguhnya. Simulasi ini hanya digunakan sebagai analisis tambahan untuk memperkirakan potensi efisiensi ukuran model apabila dukungan terhadap format presisi rendah telah tersedia secara penuh pada framework maupun perangkat keras.

3.6 Rancangan Sistem Multimedia

Sebagai bentuk implementasi dari model yang telah dikembangkan, penelitian ini merancang sebuah sistem multimedia interaktif berbasis web menggunakan framework Streamlit. Sistem dirancang agar pengguna dapat melakukan prediksi kondisi stres berbasis ekspresi wajah secara mudah tanpa perlu menjalankan kode program secara langsung.

Dashboard yang dikembangkan mendukung dua jenis masukan utama, yaitu unggah gambar dan webcam realtime.

1. Upload Gambar

Pada mode ini, pengguna dapat mengunggah gambar wajah dalam format JPG, JPEG, atau PNG melalui antarmuka dashboard. Setelah gambar berhasil diunggah, sistem secara otomatis melakukan tahapan pra-pemrosesan yang meliputi konversi grayscale, perubahan ukuran menjadi 48×48 piksel, normalisasi, dan konversi ke tensor sebelum dilakukan proses inferensi oleh model CNN.

Hasil prediksi kemudian ditampilkan dalam bentuk label stress atau non_stress beserta nilai confidence score yang menunjukkan tingkat keyakinan model terhadap hasil klasifikasi yang diberikan.

2. Webcam Realtime

Selain mendukung unggah gambar, sistem juga menyediakan fitur prediksi menggunakan webcam secara realtime. Pada mode ini, frame video dari kamera diambil secara berurutan menggunakan pustaka OpenCV, kemudian diproses menggunakan pipeline pra-pemrosesan yang sama dengan mode unggah gambar.

Setiap frame yang telah diproses akan diinferensikan oleh model sehingga hasil prediksi dapat ditampilkan secara langsung pada dashboard secara berkelanjutan.

BAB IV


IMPLEMENTASI DAN HASIL EVALUASI

4.1 Lingkungan Implementasi

Pengembangan sistem dilakukan menggunakan bahasa pemrograman Python dengan bantuan beberapa pustaka pendukung. Proses pelatihan model dilakukan menggunakan PyTorch dan torchvision sebagai framework utama deep learning. Pengolahan data dilakukan menggunakan NumPy dan Pandas, sedangkan visualisasi menggunakan Matplotlib dan Seaborn.

Evaluasi model dilakukan menggunakan library scikit-learn yang digunakan untuk menghitung accuracy, precision, recall, F1-score, dan confusion matrix. Seluruh proses eksperimen dijalankan pada Google Colab dengan dukungan GPU untuk mempercepat proses pelatihan model.

4.2 Hasil Preprocessing Dataset



Tahap preprocessing dilakukan sebelum proses pelatihan model dimulai. Dataset FER2013 yang awalnya terdiri dari tujuh kelas emosi direstrukturisasi menjadi dua kelas utama yaitu stress dan non_stress sesuai dengan tujuan penelitian.

Selain restrukturisasi kelas, dilakukan pula pengecekan data duplikat antara data train dan validation untuk menghindari terjadinya data leakage. Hasil pengecekan menunjukkan bahwa tidak ditemukan data duplikat sehingga dataset dinilai layak digunakan pada proses pelatihan dan evaluasi model.

Tahapan preprocessing lainnya meliputi proses konversi citra menjadi grayscale, resize gambar menjadi 48×48 piksel, normalisasi nilai piksel, serta augmentasi data pada data training berupa horizontal flip, rotation, dan affine transformation untuk meningkatkan variasi data.

4.3 Hasil Pelatihan Model


Setelah proses pelatihan dilakukan menggunakan dataset FER2013, diperoleh model Convolutional Neural Network (CNN) yang mampu mengklasifikasikan ekspresi wajah ke dalam dua kategori, yaitu stress dan non-stress. Seluruh proses pelatihan dilakukan menggunakan format Floating Point 32-bit (FP32) dengan konfigurasi yang telah dijelaskan pada Bab III. Model dilatih menggunakan data pelatihan dan dievaluasi pada data validasi selama maksimum 80 epoch.

Selama proses pelatihan, model menunjukkan peningkatan performa yang cukup baik. Nilai training accuracy dan validation accuracy meningkat secara bertahap pada setiap epoch, sedangkan nilai training loss dan validation loss mengalami penurunan. Kondisi tersebut menunjukkan bahwa model mampu mempelajari pola pada data pelatihan dengan baik tanpa mengalami penurunan performa yang signifikan pada data validasi.

Berdasarkan hasil training pada notebook, proses pelatihan berlangsung hingga epoch ke-80. Meskipun pada konfigurasi training telah diterapkan mekanisme early stopping, mekanisme tersebut tidak pernah aktif selama proses pelatihan berlangsung. Hal ini disebabkan karena nilai validation accuracy masih mengalami peningkatan meskipun hanya dalam jumlah yang relatif kecil pada beberapa epoch. Setiap kali terjadi peningkatan tersebut, penghitung patience kembali diatur ke nilai awal sehingga proses training tetap dilanjutkan hingga mencapai jumlah epoch maksimum.


Hasil evaluasi menunjukkan bahwa model terbaik (best checkpoint) diperoleh pada epoch ke-75 dengan nilai validation accuracy sebesar 84,97%. Setelah epoch tersebut tidak terdapat peningkatan nilai validation accuracy yang lebih tinggi hingga proses training berakhir pada epoch ke-80. Oleh karena itu, parameter model pada epoch ke-75 disimpan sebagai model terbaik dan digunakan pada seluruh proses evaluasi serta eksperimen quantization.

Pemilihan model pada epoch ke-75 dilakukan secara otomatis oleh sistem checkpoint yang digunakan selama proses pelatihan. Mekanisme ini akan menyimpan parameter model setiap kali terjadi peningkatan nilai validation accuracy. Dengan demikian, model yang digunakan pada tahap pengujian bukan merupakan model pada epoch terakhir, melainkan model yang memiliki performa terbaik terhadap data validasi.



Berdasarkan Gambar 4.5 dapat dilihat bahwa nilai *training accuracy* mengalami peningkatan yang cukup signifikan pada awal proses pelatihan. Peningkatan tersebut menunjukkan bahwa model mulai mampu mengenali pola ekspresi wajah yang terdapat pada dataset FER2013. Setelah memasuki epoch pertengahan, peningkatan akurasi menjadi lebih kecil yang menandakan bahwa model mulai mendekati kondisi konvergen.

Nilai *validation accuracy* juga menunjukkan tren peningkatan yang relatif stabil selama proses pelatihan. Meskipun terjadi sedikit fluktuasi pada beberapa epoch, secara keseluruhan performa model terus mengalami peningkatan hingga mencapai nilai terbaik pada epoch ke-75. Setelah epoch tersebut, nilai *validation accuracy* tidak mengalami peningkatan yang lebih tinggi sehingga model pada epoch ke-75 dipilih sebagai model terbaik untuk digunakan pada tahap pengujian berikutnya.



Berdasarkan Gambar 4.6 terlihat bahwa nilai *training loss* maupun *validation loss* mengalami penurunan selama proses pelatihan. Penurunan nilai *loss* menunjukkan bahwa kesalahan prediksi model semakin kecil seiring bertambahnya jumlah epoch. Walaupun masih terdapat sedikit fluktuasi pada data validasi, perubahan tersebut masih berada dalam batas yang wajar dan tidak menunjukkan gejala *overfitting* yang berlebihan. Hal ini menunjukkan bahwa model


memiliki kemampuan generalisasi yang cukup baik terhadap data yang belum pernah dilihat sebelumnya.

4.4 Hasil Evaluasi Model

Setelah proses pelatihan selesai dilakukan, model terbaik yang diperoleh pada epoch ke-75 selanjutnya dievaluasi menggunakan data validasi untuk mengetahui kemampuan model dalam melakukan klasifikasi citra wajah ke dalam kategori stress dan non-stress. Evaluasi dilakukan menggunakan beberapa metrik, yaitu accuracy, precision, recall, F1-score, confusion matrix, serta Precision–Recall Curve. Penggunaan beberapa metrik evaluasi bertujuan untuk memberikan gambaran yang lebih menyeluruh mengenai performa model, sehingga penilaian tidak hanya bergantung pada nilai accuracy saja.

Hasil evaluasi menunjukkan bahwa model memiliki performa yang baik dalam mengenali kedua kelas. Selain memperoleh nilai accuracy yang tinggi pada data validasi, model juga menunjukkan keseimbangan antara nilai precision dan recall. Hal tersebut menunjukkan bahwa model tidak hanya mampu menghasilkan prediksi yang benar, tetapi juga memiliki kemampuan yang baik dalam mengenali data pada masing-masing kelas.

4.4.1 Metrik Evaluasi




Confusion matrix digunakan untuk mengetahui jumlah prediksi yang benar maupun salah pada masing-masing kelas. Melalui confusion matrix dapat diketahui distribusi prediksi model terhadap kelas **stress** dan **non-stress**, sehingga dapat dianalisis jenis kesalahan klasifikasi yang masih dilakukan oleh model.

Berdasarkan Gambar 4.7 terlihat bahwa sebagian besar data berhasil diklasifikasikan dengan benar. Jumlah **True Positive (TP)** dan **True Negative (TN)** lebih besar dibandingkan

jumlah **False Positive (FP)** maupun **False Negative (FN)**. Hal tersebut menunjukkan bahwa model mampu mengenali pola ekspresi wajah pada kedua kelas dengan cukup baik.

Meskipun demikian, masih terdapat sejumlah kecil citra yang mengalami kesalahan klasifikasi. Kesalahan tersebut dapat dipengaruhi oleh beberapa faktor, seperti kemiripan ekspresi wajah antar kelas, pencahayaan yang kurang baik, sudut pengambilan gambar, maupun kualitas citra yang bervariasi pada dataset FER2013. Namun secara keseluruhan jumlah kesalahan tersebut relatif kecil sehingga tidak memberikan pengaruh yang signifikan terhadap performa model.



Kurva Precision-Recall menunjukkan hubungan antara precision dan recall pada berbagai nilai threshold prediksi yang digunakan oleh model.

Nilai Average Precision (AP) sebesar 0,9127 menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan kelas stress dan non_stress. Selain itu, bentuk kurva yang berada cukup dekat dengan sudut kanan atas menunjukkan bahwa model mampu mempertahankan tingkat precision yang tinggi pada sebagian besar rentang recall.

4.4.2 Classification Report

Classification Report				
	precision	recall	f1-score	support
non_stress	0.86	0.86	0.86	3838
stress	0.83	0.84	0.84	3228
accuracy			0.85	7066
macro avg	0.85	0.85	0.85	7066
weighted avg	0.85	0.85	0.85	7066


Classification report digunakan untuk mengevaluasi performa model pada setiap kelas secara lebih rinci melalui metrik precision, recall, F1-score, dan support.

Nilai precision menunjukkan kemampuan model dalam menghasilkan prediksi yang benar terhadap seluruh data yang diprediksi sebagai suatu kelas. Nilai recall menunjukkan kemampuan model dalam menemukan seluruh data yang benar-benar termasuk ke dalam suatu kelas. Sementara itu, F1-score merupakan rata-rata harmonis antara precision dan recall sehingga mampu memberikan gambaran performa model secara lebih seimbang.

Berdasarkan hasil classification report, model memperoleh nilai precision, recall, dan F1-score yang tinggi pada kedua kelas. Hal tersebut menunjukkan bahwa model memiliki kemampuan yang baik dalam mengenali ekspresi wajah baik pada kelas stress maupun non-stress. Nilai F1-score yang tinggi juga menunjukkan bahwa model memiliki keseimbangan yang baik antara kemampuan mendeteksi data positif dan meminimalkan kesalahan prediksi.

Secara keseluruhan hasil classification report mendukung hasil accuracy yang telah diperoleh sebelumnya sehingga dapat disimpulkan bahwa model memiliki kemampuan klasifikasi yang baik sebelum dilakukan proses quantization.

4.4.3 Precision–Recall Curve



Selain menggunakan confusion matrix dan classification report, penelitian ini juga melakukan evaluasi menggunakan **Precision–Recall Curve (PR Curve)**. Kurva ini digunakan untuk menggambarkan hubungan antara nilai **precision** dan **recall** pada berbagai nilai threshold. Berbeda dengan accuracy yang hanya memberikan satu nilai performa, Precision–Recall Curve mampu menunjukkan perubahan kemampuan model dalam mempertahankan precision ketika nilai recall meningkat.

Pada Gambar 4.8 terlihat bahwa kurva berada pada bagian atas grafik untuk sebagian besar rentang nilai recall. Kondisi tersebut menunjukkan bahwa model mampu

mempertahankan nilai precision yang tinggi ketika berhasil mendeteksi sebagian besar data positif. Penurunan nilai precision baru terlihat ketika recall mendekati nilai maksimum. Hal ini merupakan karakteristik yang umum terjadi pada model klasifikasi, karena semakin banyak data positif yang berhasil dikenali, semakin besar pula kemungkinan munculnya prediksi positif yang kurang tepat.

Berdasarkan hasil evaluasi diperoleh nilai **Average Precision (AP) sebesar 0,9127**. Nilai tersebut menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan kedua kelas yang digunakan pada penelitian ini. Semakin mendekati nilai 1, maka semakin baik performa model dalam mempertahankan keseimbangan antara precision dan recall.

Hasil evaluasi menggunakan Precision–Recall Curve memperkuat hasil evaluasi sebelumnya yang diperoleh melalui confusion matrix dan classification report. Dengan nilai Average Precision sebesar **0,9127**, model CNN yang dikembangkan pada penelitian ini memiliki kemampuan klasifikasi yang baik sehingga layak digunakan sebagai model dasar sebelum dilakukan proses precision reduction dan quantization.


4.5 Hasil Eksperimen Precision dan Quantization

Setelah model terbaik diperoleh pada proses pelatihan, tahap berikutnya adalah melakukan eksperimen precision reduction dan quantization. Tujuan dari eksperimen ini adalah untuk mengetahui pengaruh perubahan representasi parameter model terhadap performa klasifikasi, ukuran model, serta waktu inferensi (latency). Seluruh eksperimen dilakukan menggunakan model terbaik hasil pelatihan pada epoch ke-75 yang sebelumnya disimpan sebagai best checkpoint.

Pada penelitian ini, model Floating Point 32-bit (FP32) digunakan sebagai model acuan (baseline model). Selanjutnya dilakukan konversi model ke format Floating Point 16-bit (FP16) dan Dynamic Quantization Integer 8-bit (QINT8). Selain kedua metode tersebut, penelitian ini juga melakukan eksperimen terhadap FP8 native serta simulasi FLOAT8, FLOAT4, dan QINT4 sebagai analisis tambahan.

Eksperimen ini bertujuan untuk mengetahui sejauh mana pengurangan presisi dapat meningkatkan efisiensi model tanpa menyebabkan penurunan performa klasifikasi yang signifikan. Evaluasi dilakukan berdasarkan beberapa aspek, yaitu akurasi klasifikasi, ukuran model, dan waktu inferensi.

1. Precision




Gambar 4.9 memperlihatkan hasil prediksi model terhadap beberapa citra pada data uji yang dikelompokkan ke dalam dua kelas, yaitu Non-Stress dan Stress. Setiap citra menampilkan label sebenarnya (*True*), hasil prediksi model (*Pred*), serta nilai *confidence score* yang menunjukkan tingkat keyakinan model terhadap hasil klasifikasi.

Pada kelompok Non-Stress, sebagian besar citra berhasil diklasifikasikan dengan benar. Hal ini ditunjukkan oleh kesesuaian antara label sebenarnya dan hasil prediksi yang ditandai dengan teks berwarna hijau. Meskipun demikian, masih terdapat beberapa citra yang mengalami kesalahan klasifikasi, yaitu ketika citra dengan label Non-Stress diprediksi sebagai Stress. Kesalahan tersebut menunjukkan bahwa beberapa ekspresi wajah memiliki karakteristik yang menyerupai ekspresi stres sehingga menyulitkan model dalam melakukan klasifikasi.

Sementara itu, pada kelompok Stress, sebagian besar citra juga berhasil dikenali dengan benar oleh model. Namun, masih terdapat beberapa kesalahan prediksi, yaitu citra dengan label Stress yang diprediksi sebagai Non-Stress. Kondisi ini kemungkinan dipengaruhi oleh variasi ekspresi wajah, pencahayaan, sudut pengambilan gambar, maupun kualitas citra yang menyebabkan perbedaan karakteristik fitur menjadi kurang jelas.

Secara keseluruhan, hasil visualisasi menunjukkan bahwa model mampu mengklasifikasikan sebagian besar citra pada kedua kelas dengan baik. Hal ini mengindikasikan bahwa model telah berhasil mempelajari pola-pola ekspresi wajah yang berkaitan dengan kondisi

Stress dan Non-Stress, meskipun masih terdapat beberapa kesalahan klasifikasi pada citra dengan karakteristik yang mirip antar kelas.




Selain dilakukan pengujian menggunakan data uji dari dataset FER2013, model juga diuji menggunakan MyTest Dataset yang berisi citra wajah yang dikumpulkan secara mandiri. Pengujian ini bertujuan untuk mengetahui kemampuan model dalam mengenali ekspresi wajah pada data yang lebih bervariasi dan berbeda dari data pelatihan.


Berdasarkan Gambar 4.10, sebagian besar citra berhasil diklasifikasikan sesuai dengan label yang diberikan. Hal ini menunjukkan bahwa model memiliki kemampuan generalisasi yang cukup baik terhadap data baru. Namun, masih terdapat beberapa citra yang mengalami kesalahan klasifikasi. Kesalahan tersebut kemungkinan disebabkan oleh variasi pencahayaan, posisi wajah, kualitas citra, serta kemiripan karakteristik antar ekspresi yang menyebabkan model mengalami kesulitan dalam membedakan kelas yang diprediksi.

Hasil pengujian pada MyTest Dataset menunjukkan bahwa model tetap mampu memberikan performa yang baik ketika diterapkan pada data di luar dataset pelatihan, sehingga mendukung penggunaan model pada implementasi sistem yang dikembangkan.


2. Hasil Quantization



FP32



FP16



QIN8

Gambar 4.11 menampilkan perbandingan hasil prediksi model setelah dilakukan proses quantization menggunakan tiga format representasi data, yaitu FP32, FP16, dan QINT8, terhadap kumpulan data uji (*mytest dataset*). Setiap model digunakan untuk mengklasifikasikan citra wajah ke dalam dua kelas, yaitu Stress dan Non-Stress, kemudian hasil prediksi ditampilkan beserta label sebenarnya dan nilai *confidence score*.

Berdasarkan hasil visualisasi, model FP32 mampu mengklasifikasikan sebagian besar citra dengan benar. Sebagian besar prediksi ditunjukkan dengan teks berwarna hijau yang menandakan kesesuaian antara label sebenarnya dan hasil prediksi. Namun, masih terdapat beberapa citra yang mengalami kesalahan klasifikasi yang ditandai dengan teks berwarna merah. Kesalahan tersebut umumnya terjadi pada citra yang memiliki karakteristik ekspresi wajah yang mirip antara kelas Stress dan Non-Stress, sehingga model mengalami kesulitan dalam membedakan kedua kelas tersebut.

Hasil prediksi menggunakan model FP16 menunjukkan pola yang hampir sama dengan model FP32. Meskipun ukuran model berkurang hingga sekitar 50% dibandingkan FP32, model FP16 tetap mampu mempertahankan kualitas prediksi pada sebagian besar citra. Hal ini menunjukkan bahwa proses konversi ke presisi 16-bit tidak memberikan penurunan performa yang

signifikan, sehingga model masih mampu melakukan klasifikasi secara akurat dengan waktu inferensi yang lebih cepat.

Sementara itu, model QINT8 menghasilkan ukuran model paling kecil setelah proses quantization. Berdasarkan hasil visualisasi, model ini tetap mampu memberikan prediksi yang baik pada sebagian besar citra dalam *mytest dataset*. Bahkan, berdasarkan hasil evaluasi yang diperoleh, model QINT8 menghasilkan nilai akurasi sebesar 0,8631, lebih tinggi dibandingkan model FP32 (0,8365) maupun FP16 (0,8363). Hasil tersebut menunjukkan bahwa proses quantization ke format integer 8-bit tidak menurunkan kemampuan model dalam melakukan klasifikasi pada data pengujian yang digunakan, tetapi justru memberikan peningkatan performa pada penelitian ini.

Secara keseluruhan, visualisasi hasil prediksi menunjukkan bahwa proses quantization berhasil menghasilkan model yang lebih efisien tanpa mengurangi kualitas klasifikasi secara signifikan. Model FP16 memberikan keuntungan berupa waktu inferensi tercepat, sedangkan QINT8 menjadi model yang paling efisien karena memiliki ukuran model paling kecil sekaligus menghasilkan akurasi terbaik pada data pengujian. Dengan demikian, hasil eksperimen menunjukkan bahwa teknik quantization layak diterapkan sebagai salah satu metode optimasi model CNN untuk proses klasifikasi citra wajah, terutama pada implementasi yang membutuhkan efisiensi memori dan kecepatan inferensi.

3. Tabel Perbandingan Quantization

Model	Accuracy	Ukuran	Latency
FP32	0.8365	44.8	12.3
FP16	0.836,3	22.4	5.8
QIN8	0.863,1	12.1	7.2

Berdasarkan Tabel hasil eksperimen menunjukkan bahwa proses quantization memberikan pengaruh terhadap ukuran model, waktu inferensi, dan akurasi. Model FP32 memperoleh nilai akurasi sebesar 0,8365, dengan ukuran model 44,8 MB dan waktu inferensi 12,3 ms. Setelah dilakukan konversi ke format FP16, ukuran model berkurang menjadi 22,4 MB atau sekitar 50% lebih kecil dibandingkan FP32. Selain itu, waktu inferensi juga menjadi lebih cepat, yaitu 5,8 ms, dengan akurasi yang relatif tetap sebesar 0,8363.

Sementara itu, model QINT8 menghasilkan ukuran model paling kecil, yaitu 12,1 MB, dengan waktu inferensi sebesar 7,2 ms. Berdasarkan hasil pengujian pada penelitian ini, model QINT8 memperoleh nilai akurasi sebesar 0,8631, sehingga menjadi model dengan akurasi tertinggi dibandingkan FP32 maupun FP16. Hasil tersebut menunjukkan bahwa proses quantization pada

format QINT8 tidak hanya berhasil mengurangi ukuran model secara signifikan, tetapi juga tetap mampu mempertahankan bahkan meningkatkan performa klasifikasi pada data pengujian yang digunakan.

Secara keseluruhan, model FP16 memberikan waktu inferensi paling cepat sehingga sesuai untuk implementasi pada perangkat yang mendukung komputasi *floating-point* 16-bit. Di sisi lain, model QINT8 menjadi alternatif yang sangat baik untuk implementasi pada perangkat dengan keterbatasan sumber daya karena memiliki ukuran model paling kecil serta memberikan akurasi terbaik pada pengujian dalam penelitian ini.


4.6 Implementasi Dashboard Sistem Multimedia

Setelah proses pelatihan dan evaluasi model selesai dilakukan, model CNN kemudian diintegrasikan ke dalam aplikasi berbasis Streamlit sebagai bentuk implementasi sederhana dari sistem deteksi stres berbasis ekspresi wajah.

Penggunaan Streamlit dipilih karena mampu menyediakan antarmuka interaktif yang mudah digunakan serta mendukung integrasi langsung dengan model deep learning berbasis Python. Dashboard yang dikembangkan memungkinkan pengguna melakukan proses prediksi tanpa perlu menjalankan kode program secara manual.

Pada tahap implementasi ini, model yang telah dilatih digunakan untuk melakukan inferensi terhadap gambar wajah yang diberikan oleh pengguna. Sistem kemudian menampilkan hasil klasifikasi berupa label stress atau non_stress beserta tingkat keyakinan prediksi (confidence score) yang dihasilkan oleh model.

4.6.1 Fitur Dashboard



Dashboard Streamlit dikembangkan sebagai antarmuka pengguna untuk mempermudah proses prediksi kondisi stres berbasis ekspresi wajah menggunakan model CNN yang telah dilatih sebelumnya.


Pada halaman utama, dashboard menampilkan informasi status aplikasi, metode inferensi yang digunakan, serta beberapa menu utama yang dapat digunakan oleh pengguna.

Fitur-fitur yang tersedia pada dashboard meliputi:

1. Unggah Foto, digunakan untuk melakukan prediksi menggunakan gambar wajah yang diunggah oleh pengguna.
2. Webcam, digunakan untuk melakukan pengambilan gambar secara langsung menggunakan kamera perangkat.
3. Riwayat, digunakan untuk menampilkan hasil prediksi yang telah dilakukan sebelumnya.
4. Status Aplikasi, digunakan untuk menunjukkan bahwa model dan layanan inferensi berjalan dengan baik.
5. Informasi Model, menampilkan informasi mengenai model yang digunakan, meliputi dataset FER2013, ukuran citra 48×48 piksel grayscale, serta penggunaan model hasil quantization FP16.

Selain itu, dashboard juga menampilkan informasi performa model berupa akurasi sebesar sekitar 90%, penggunaan model FP16 sebagai metode inferensi, serta rata-rata latency inferensi sekitar 40 ms.

4.6.2 Hasil Pengujian Dashboard



Pengujian dashboard dilakukan menggunakan citra wajah yang diunggah oleh pengguna melalui fitur unggah foto.

Setelah gambar berhasil diunggah, sistem secara otomatis melakukan preprocessing berupa konversi citra menjadi grayscale dengan ukuran 48×48 piksel sesuai dengan format input model CNN.

Berdasarkan hasil pengujian, model memberikan prediksi cenderung tenang (non-stress) dengan tingkat keyakinan sebesar 61,69%, sedangkan probabilitas untuk kelas stress sebesar 38,31%.

Hasil tersebut menunjukkan bahwa model tidak hanya memberikan label klasifikasi, tetapi juga menampilkan distribusi probabilitas pada masing-masing kelas sehingga pengguna dapat memahami tingkat keyakinan model terhadap hasil prediksi yang diberikan.

Proses inferensi dapat dilakukan secara cepat dengan latency rata-rata sekitar 40 ms, sehingga dashboard memiliki potensi untuk digunakan pada implementasi sistem deteksi stres secara realtime.

BAB V

PENGUJIAN DAN EVALUASI SISTEM

5.1 Hasil Pengujian Sistem

Pengujian sistem dilakukan untuk memastikan bahwa seluruh komponen yang dikembangkan, mulai dari tahap preprocessing, pelatihan model CNN, eksperimen precision dan quantization, hingga implementasi dashboard realtime, dapat berjalan sesuai dengan tujuan penelitian. Pengujian dilakukan menggunakan dataset FER2013 serta beberapa citra wajah pada dashboard Streamlit.

Hasil pengujian sistem disajikan pada tabel berikut.

Kode	Skenario	Hasil
T01	Preprocessing dataset	Seluruh gambar berhasil diproses menjadi grayscale 48×48 dan dinormalisasi.
T02	Restrukturisasi kelas	Dataset berhasil diubah menjadi dua kelas: stress dan non_stress.
T03	Data leakage	Tidak ditemukan data duplikat menggunakan hashing MD5.
T04	Training CNN FP32	Validation accuracy terbaik mencapai sekitar 84,7%.
T05	Evaluasi model	Accuracy 85%, Average Precision 0,9127, confusion matrix berhasil dibuat.
T06	FP16 Half Precision	Ukuran model lebih kecil dengan akurasi tetap kompetitif.

T07	QINT8 Quantization	Inferensi CPU lebih efisien dengan penurunan performa yang sangat kecil.
T08	Dashboard Realtime	Upload gambar dan webcam berhasil menampilkan prediksi beserta confidence score.


Berdasarkan hasil pengujian, seluruh fungsi utama sistem berhasil dijalankan sesuai dengan tujuan proyek. Tahap preprocessing mampu menghasilkan data yang siap digunakan pada proses pelatihan. Model CNN berhasil mencapai validation accuracy sebesar 84,7% dan accuracy pengujian sebesar 85%. Selain itu, implementasi FP16 dan QINT8 mampu meningkatkan efisiensi model tanpa menyebabkan penurunan performa yang signifikan. Dashboard Streamlit juga berhasil menampilkan hasil prediksi secara realtime baik melalui unggahan gambar maupun webcam.

5.2 Evaluasi Sistem Multimedia

Evaluasi sistem multimedia dilakukan untuk menilai apakah dashboard realtime yang dikembangkan mampu menjalankan proses deteksi stres berbasis ekspresi wajah secara interaktif dan responsif.

Berdasarkan hasil implementasi, dashboard berhasil menjalankan seluruh fungsi utama sesuai rancangan. Pengguna dapat melakukan prediksi melalui unggah gambar maupun webcam secara langsung. Setelah gambar diterima, sistem melakukan preprocessing otomatis berupa konversi ke grayscale, resize menjadi 48×48 piksel, dan normalisasi sebelum model CNN menghasilkan prediksi.

Hasil prediksi ditampilkan dalam bentuk label kelas (stress atau non_stress) beserta confidence score, sehingga pengguna dapat mengetahui tingkat keyakinan model terhadap hasil prediksi yang diberikan.



Pengujian menunjukkan bahwa rata-rata waktu inferensi sekitar 40 ms, sehingga sistem mampu memberikan respons dengan cepat dan mendukung penggunaan secara realtime. Antarmuka dashboard yang dikembangkan menggunakan Streamlit juga dinilai sederhana dan mudah digunakan karena seluruh proses dilakukan tanpa memerlukan interaksi langsung dengan kode program.

Meskipun demikian, performa sistem masih dipengaruhi oleh kualitas gambar masukan, pencahayaan, posisi wajah, serta spesifikasi perangkat yang digunakan.

5.3 Analisis Risiko dan Mitigasi

Selama pelaksanaan proyek, beberapa risiko diidentifikasi dan ditangani sebagai berikut:

 Risiko & Mitigasi		
Risiko	Dampak	Mitigasi
Gambar blur / pencahayaan buruk	Model sulit mengenali ekspresi	Preprocessing dan augmentasi data
Data leakage	Evaluasi tidak valid	Pengecekan hashing MD5
Overfitting	Performa validasi menurun	Dropout, augmentasi, early stopping
Accuracy rendah	Model belum optimal	Tuning hyperparameter dan arsitektur
FP16/QINT8 tidak stabil	Perbandingan tidak lengkap	FP32 digunakan sebagai baseline
Webcam bermasalah	Dashboard tidak dapat digunakan	Fitur upload gambar sebagai alternatif

Berdasarkan pelaksanaan proyek, sebagian besar risiko yang telah diidentifikasi berhasil diminimalkan melalui strategi mitigasi yang diterapkan. Risiko data leakage berhasil diatasi melalui pengecekan duplikasi menggunakan hashing MD5 sehingga validitas proses evaluasi tetap terjaga. Risiko overfitting dapat dikurangi melalui penerapan augmentasi data, dropout, early stopping, serta penyesuaian learning rate selama proses pelatihan.

Pada tahap implementasi dashboard, potensi kegagalan akses webcam diantisipasi dengan menyediakan fitur unggah gambar sebagai alternatif proses inferensi. Pendekatan tersebut membuat sistem tetap dapat digunakan meskipun terdapat keterbatasan perangkat pengguna.

5.4 Kelebihan dan Keterbatasan Sistem

Adapun kelebihan dan kekurangan pada system:

A. Kelebihan

- Model CNN mencapai accuracy sekitar 85%.
- Preprocessing dataset dilakukan secara komprehensif.
- Tidak ditemukan data leakage.
- Dashboard mendukung prediksi realtime.
- Model FP16 lebih efisien dibanding FP32.
- Sistem mudah dijalankan melalui Streamlit.

B. Kekurangan

- Hanya menggunakan dataset FER2013.
- Deteksi didasarkan pada ekspresi wajah saja.
- Bukan alat diagnosis psikologis klinis.
- Performa dipengaruhi pencahayaan dan posisi wajah.
- Masih menggunakan binary classification.
- Low-bit quantization masih berupa simulasi.

BAB VI

PENUTUP

6.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, pengujian, dan evaluasi yang telah dilakukan, dapat disimpulkan bahwa proyek Deteksi Stres Berbasis Ekspresi Wajah Menggunakan Convolutional Neural Network (CNN) dengan Perbandingan Precision dan Quantization berhasil dikembangkan sesuai dengan tujuan penelitian. Adapun kesimpulan yang diperoleh adalah sebagai berikut.

1. Model EmotionCNNDeepFC berhasil dirancang dan diimplementasikan untuk melakukan klasifikasi biner ekspresi wajah menjadi kelas stress dan non_stress menggunakan dataset FER2013 yang telah direstrukturasikan. Model mampu mempelajari karakteristik ekspresi wajah sehingga dapat digunakan untuk mendeteksi indikasi stres berdasarkan citra wajah.
2. Tahap preprocessing dataset berhasil dilakukan dengan baik melalui restrukturisasi kelas, pengecekan data leakage menggunakan hashing MD5, normalisasi citra, serta augmentasi data. Seluruh proses tersebut menghasilkan data yang valid dan siap digunakan dalam pelatihan model sehingga mampu meningkatkan kualitas pembelajaran serta kemampuan generalisasi model.
3. Hasil evaluasi menunjukkan bahwa model CNN memperoleh validation accuracy sebesar 84,7% dan accuracy pengujian sebesar 85%, dengan nilai Average Precision (AP) sebesar 0,9127. Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan kelas stress dan non_stress, sehingga target penelitian berupa akurasi minimal 80% berhasil tercapai.
4. Eksperimen precision reduction dan quantization menunjukkan bahwa penggunaan FP16 dan QINT8 mampu meningkatkan efisiensi model dibandingkan FP32. FP16 memberikan keseimbangan terbaik antara akurasi dan efisiensi komputasi, sedangkan QINT8 memberikan keuntungan dalam proses inferensi pada perangkat berbasis CPU tanpa penurunan performa yang berarti.
5. Implementasi sistem multimedia menggunakan Streamlit berhasil mengintegrasikan model CNN ke dalam dashboard interaktif yang mendukung fitur unggah gambar dan webcam realtime. Sistem mampu memberikan hasil prediksi beserta confidence score dengan waktu inferensi yang relatif cepat sehingga berpotensi digunakan sebagai media demonstrasi maupun pembelajaran mengenai penerapan deep learning pada pengenalan ekspresi wajah.

Secara keseluruhan, proyek ini menunjukkan bahwa kombinasi antara Convolutional Neural Network, teknik precision reduction, dan quantization dapat menghasilkan sistem deteksi

stres berbasis ekspresi wajah yang memiliki performa klasifikasi yang baik sekaligus lebih efisien untuk proses deployment pada aplikasi multimedia.

6.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dijadikan acuan untuk pengembangan penelitian selanjutnya.

1. Menggunakan dataset ekspresi wajah yang lebih beragam dan representatif, baik dari sisi jumlah data, variasi usia, jenis kelamin, maupun latar belakang etnis, sehingga model memiliki kemampuan generalisasi yang lebih baik.
2. Mengembangkan arsitektur model dengan memanfaatkan jaringan yang lebih ringan dan efisien, seperti MobileNet, EfficientNet, atau model berbasis Vision Transformer (ViT), sehingga sistem dapat diterapkan pada perangkat dengan sumber daya komputasi yang terbatas.
3. Mengimplementasikan teknik native quantization menggunakan framework seperti TensorRT, ONNX Runtime, atau TensorFlow Lite agar optimasi model tidak hanya berupa simulasi, tetapi dapat diterapkan secara langsung pada proses deployment.
4. Mengembangkan sistem menjadi aplikasi mobile atau edge computing sehingga proses deteksi stres dapat dilakukan secara lebih fleksibel melalui smartphone maupun perangkat IoT.
5. Mengintegrasikan sumber informasi lain selain ekspresi wajah, seperti analisis suara, detak jantung, atau sinyal fisiologis, sehingga proses identifikasi kondisi stres menjadi lebih akurat dan tidak hanya bergantung pada satu jenis data.
6. Melakukan pengujian sistem terhadap pengguna secara lebih luas serta melibatkan tenaga ahli di bidang psikologi atau kesehatan mental untuk mengevaluasi kesesuaian hasil prediksi dengan kondisi psikologis pengguna yang sebenarnya. Langkah ini penting agar sistem dapat dikembangkan lebih lanjut sebagai alat bantu skrining awal, bukan sebagai alat diagnosis klinis.

DAFTAR PUSTAKA

- [1] S. I. Young, D. Taubman, W. Zhe, and B. Girod, "Transform Quantization for CNN Compression," *IEEE Transactions on Image Processing*, vol. 30, pp. 761-775, 2021.
- [2] I. Harjanto, M. Amiruddin, and B. H. Kunaryo, "Optimasi Model Deep Learning untuk Raspberry Menggunakan Pruning dan Kuantisasi," *Jurnal Ilmiah Teknologi Informasi dan Komunikasi (JTik)*, vol. 15, no. 2, pp. 360-370, 2024.
- [3] F. W. Prabowo, A. Homaidi, and A. Lutfi, "Deteksi Warna Kulit Menggunakan Metode Deep Learning dengan CNN untuk Menentukan Kecocokan Warna Kulit dan Warna Busana," *Jurnal Ilmiah Teknologi Informasi dan Komunikasi (JTik)*, vol. 15, no. 2, pp. 360-370, 2024.
- [4] I. K. Khairullah, A. Yusa, A. D. Hartanto, Hartatik, and Kusnawi, "Deteksi Citra Digital Menggunakan Algoritma CNN dengan Model Normalisasi RGB," *Jurnal Informatika dan Pengolahan Citra Digital*, 2023.
- [5] N. N. Ali and A. M. Abdulazeez, "Facial Emotion Recognition Based on Deep Learning: A Review," *Indonesian Journal of Computer Science*, vol. 13, no. 1, 2024.
- [6] D. Pruthviraja, U. M. Kumar, S. Parameswaran, V. G. Chowdary, and V. Bharadwaj, "Deep Convolutional Neural Network Architecture for Facial Emotion Recognition," *PeerJ Computer Science*, vol. 10, e2339, 2024.
- [7] J. W. Kusno and A. Chowanda, "Modeling Emotion Recognition System from Facial Images Using Convolutional Neural Networks," *CommIT Journal*, vol. 18, no. 2, pp. 251-259, 2024.
- [8] R. A. Elsheikh, M. A. Mohamed, A. M. Abou-Taleb, and M. M. Ata, "Improved Facial Emotion Recognition Model Based on a Novel Deep Convolutional Structure," *Scientific Reports*, vol. 14, no. 1, 2024.
- [9] Y. Khairuddin and Z. Chen, "Facial Emotion Recognition: State of the Art Performance on FER2013," *arXiv preprint arXiv:2105.03588*, 2021.
- [10] O. C. Oguine, K. J. Oguine, H. I. Bisallah, and D. Ofuani, "Hybrid Facial Expression Recognition (FER2013) Model for Real-Time Emotion Classification and Prediction," *arXiv preprint arXiv:2206.09509*, 2022.
- [11] I. Goodfellow et al., "Challenges in Representation Learning: A Report on Three Machine Learning Contests," in *Proc. NIPS Workshop*, 2013.
- [12] B. Jacob et al., "Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference," in *Proc. IEEE CVPR*, pp. 2704-2713, 2018.

- [13] A. G. Howard et al., "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," arXiv preprint arXiv:1704.04861, 2017.
- [14] D. T. Long, "A Facial Expressions Recognition Method Using Residual Network Architecture for Online Learning Evaluation," Journal of Advanced Computational Intelligence and Intelligent Informatics, vol. 25, no. 6, pp. 953-962, 2021.
- [15] A. A. H. Qutub and Y. Atay, "Deep Learning Approaches for Classification of Emotion Recognition Based on Facial Expressions," Nexa Revista Cientifica, vol. 36, no. 5, pp. 1-18, 2023.

LAMPIRAN

Lampiran A: Pembagian Tugas Tim

Berikut adalah pembagian tugas dan kontribusi masing-masing anggota tim:

Nama	Peran	Tanggung Jawab Utama	Deliverable
Fitri Fatimah	Koordinator Proyek & Deep Learning	Koordinasi alur kerja tim, perancangan model CNN, metodologi, integrasi sistem	Rancangan model CNN, koordinasi proyek, metodologi
Kanaya Dzikra Setiadi	Data Preparation & Quantization	Restrukturisasi dataset, preprocessing, augmentasi, pengecekan data leakage, eksperimen FP16 & QINT8	Dataset siap training, pipeline preprocessing, hasil eksperimen quantization
Nashwa	Evaluasi Model & Analisis Hasil	Evaluasi model (accuracy, precision, recall, F1-score, confusion matrix, ROC-AUC), visualisasi dan analisis perbandingan model	Hasil evaluasi model, confusion matrix, ROC-AUC, grafik perbandingan
Amelia Regina Permana	Sistem Multimedia & Dashboard Realtime	Perancangan dan pengembangan dashboard realtime, fitur upload gambar, webcam, UI/UX sistem	Prototype dashboard realtime, fitur upload & webcam, tampilan output prediksi

Lampiran B: Jadwal Pelaksanaan Proyek

Minggu	Aktivitas Utama	Output
1	Studi literatur CNN, FER2013, quantization, sistem multimedia	Ringkasan teori dan referensi awal
2	Definisi masalah, rumusan kebutuhan, rancangan solusi	Rumusan masalah, tujuan, batasan
3	Pengumpulan dan pemeriksaan struktur dataset FER2013	Dataset tersedia, struktur teridentifikasi
4	Restrukturisasi dari 7 kelas menjadi stress dan non stress	Dataset dua kelas siap
5	Preprocessing dan augmentasi citra	Pipeline preprocessing & augmentasi
6	Perancangan arsitektur model CNN EmotionCNNDeepFC	Struktur model CNN
7	Implementasi baseline model CNN FP32	Model baseline dapat dijalankan
8	Training model CNN dan pemantauan validation	Model CNN terlatih
9	Evaluasi model (accuracy, precision, recall, F1, CM, ROC-AUC)	Hasil evaluasi dan visualisasi
10	Implementasi eksperimen FP16 dan QINT8	Varian FP16 & QINT8 siap dibandingkan
11	Simulasi FLOAT8, FLOAT4, QINT4 dan analisis perbandingan	Tabel dan grafik perbandingan
12	Perancangan dan implementasi dashboard realtime	Prototype dashboard
13	Integrasi model CNN ke dashboard, pengujian upload & webcam	Sistem terintegrasi
14	Penyusunan laporan, slide presentasi, dan persiapan demo	Laporan akhir, slide, demo

Lampiran C: Deliverables Proyek

Berikut Kami lampirkan untuk file pendukung lainnya tercantum di dalam link github di bawah ini

(<https://github.com/AmeliaReginaa/PROJECT-AKHIR-DEEP-LEARNING-SISTEM-MULTIMEDIA>)