

MATA KULIAH DEEP LEARNING & SISTEM MULTIMEDIA

DETEKSI STRESS BERBASIS EKSPRESI WAJAH MENGUNAKAN CNN DAN PERBANDINGAN OPTIMASI QUANTIZATION MENGGUNAKAN DASHBOARD INTERAKTIF


DISUSUN OLEH:

NASYWA NUR H | 2C2250004

FITRI FATIMAH | 2C2230004

KANAYA DZIKRA | 2C2230015

AMELIA REGINA | 2C2230019



LATAR BELAKANG


Perkembangan teknologi deep learning dan sistem multimedia memungkinkan proses analisis citra dilakukan secara otomatis dan realtime. Salah satu bentuk implementasinya adalah deteksi kondisi emosional melalui ekspresi wajah. Namun, proses identifikasi stress secara manual masih bersifat subjektif dan tidak selalu dapat dilakukan secara cepat.

Ekspresi wajah dapat digunakan sebagai indikator visual untuk memperkirakan kondisi stress karena wajah memiliki pola seperti bentuk mata, alis, dan mulut yang dapat dianalisis menggunakan computer vision. Oleh karena itu, pada proyek ini digunakan Convolutional Neural Network (CNN) untuk melakukan klasifikasi stress dan non_stress dari citra wajah.

Selain membangun model deep learning, proyek ini juga mengintegrasikan model ke dalam dashboard interaktif berbasis multimedia yang mendukung upload gambar dan webcam realtime. Untuk mendukung performa sistem realtime, dilakukan optimasi model menggunakan quantization agar inferensi menjadi lebih ringan dan cepat.

MOTIVASI PROJECT

Proyek ini bertujuan membangun sistem deteksi stres berbasis ekspresi wajah menggunakan CNN. Selain melakukan klasifikasi stress dan non_stress, proyek juga menganalisis precision dan quantization seperti FP32, FP16, dan QINT8 untuk optimasi ukuran model dan kecepatan inferensi. Model nantinya akan diintegrasikan ke dashboard multimedia realtime berbasis gambar dan webcam.



TUJUAN PROYEK



- Membangun model CNN untuk klasifikasi stress dan non_stress dari citra wajah.
- Melakukan preprocessing dan cleaning dataset untuk mencegah data leakage.
- Mengevaluasi performa model menggunakan metrik klasifikasi.
- Mengembangkan dashboard multimedia interaktif untuk deteksi stress melalui upload gambar dan webcam realtime.
- Melakukan optimasi model menggunakan FP16 dan QINT8 agar deployment realtime lebih ringan dan cepat.

RUMUSAN MASALAH

1. Bagaimana membangun model CNN untuk klasifikasi stress dan non_stress dari ekspresi wajah?
2. Bagaimana mencegah data leakage pada dataset train dan validation agar evaluasi model valid?
3. Seberapa baik performa model berdasarkan accuracy, precision, recall, F1-score, dan confusion matrix?
4. Bagaimana pengaruh quantization terhadap ukuran model, akurasi, dan latency inferensi pada sistem realtime?
5. Bagaimana mengintegrasikan model CNN ke dalam dashboard multimedia interaktif berbasis upload gambar dan webcam realtime?

BATASAN

Aspek	Penjelasan
Dataset	Menggunakan dataset FER2013 dengan citra grayscale berukuran 48×48 piksel
Kelas	Dataset direstrukturisasi menjadi dua kelas, yaitu stress dan non_stress
Model	Menggunakan custom Convolutional Neural Network (CNN)
Jenis Klasifikasi	Binary image classification
Output Model	Output hanya berupa kelas stress dan non_stress

Precision & Quantization	Menggunakan FP32, FP16, dan QINT8 sebagai real variant
Low-bit Precision	FLOAT8, FLOAT4, dan QINT4 hanya berupa simulasi
Multimedia	Dashboard realtime berbasis upload gambar dan webcam
Deployment	Sistem masih berupa prototype pembelajaran
Diagnosis	Sistem bukan alat diagnosis medis

ASUMSI

Asumsi	Penjelasan
Ekspresi Wajah	Ekspresi wajah diasumsikan dapat merepresentasikan indikasi stres
Dataset	Dataset FER2013 dianggap cukup representatif untuk eksperimen klasifikasi
Low-bit Precision	FLOAT8, FLOAT4, dan QINT4 hanya merepresentasikan estimasi ukuran model
Hardware	GPU dan CPU yang digunakan dianggap cukup untuk training dan inferensi
Dashboard	Webcam dan gambar input diasumsikan memiliki kualitas yang cukup untuk diproses model

METODOLOGI PENELITIAN

Flowchart Alur Kerja Umum Proyek

Deteksi Stres Berbasis Ekspresi Wajah Menggunakan CNN dengan Perbandingan Precision dan Quantization



Tipe Tugas

- Supervised binary image classification

Input

- Citra wajah grayscale 48×48

Output

- stress
- non_stress

ALUR SISTEM

Input Gambar / Webcam



Preprocessing Realtime



CNN Inference



Prediction



Dashboard Output

Sistem Multimedia (Web Streamlit)

- Upload Foto Wajah
- Realtime Webcam Detection
- Prediksi Stress / Non-Stress
- Confidence Score
- Visualisasi Hasil Prediksi

Deployment Recommendation

- FP16 → GPU deployment
- QINT8 → CPU deployment

RENCANA IMPLEMENTASI & ARSITEKTUR SISTEM

Sistem diimplementasikan menggunakan Python dan PyTorch untuk membangun model CNN, melakukan preprocessing citra, evaluasi model, optimasi precision/quantization, serta menampilkan hasil prediksi melalui dashboard realtime.

Komponen	Teknologi / Modul	Fungsi
Bahasa & Framework	Python, PyTorch	Membangun dan melatih model CNN
Preprocessing Citra	torchvision, OpenCV	Grayscale, resize 48×48, normalisasi
Model CNN	EmotionCNNDeepFC	Klasifikasi wajah menjadi stress / non_stress
Evaluasi Model	scikit-learn, Matplotlib	Menghitung metrik dan membuat visualisasi
Optimasi Model	FP32, FP16, QINT8	Membandingkan akurasi, ukuran model, dan latency
Dashboard Realtime	Streamlit / Gradio	Menampilkan upload gambar, webcam, prediksi, dan confidence score

RENCANA PENGUJIAN DAN EVALUASI

Pengujian dilakukan untuk mengevaluasi performa model CNN, efisiensi optimasi precision/quantization, serta fungsi dashboard realtime. Model dievaluasi menggunakan accuracy, precision, recall, F1-score, ROC-AUC, confusion matrix, latency, ukuran model, dan uji fungsional dashboard.

Kode uji	Skenario/fitur	Data/parameter	Metrik	Target
T01	Pengujian preprocessing dataset	Dataset FER2013, resize 48×48, grayscale, normalisasi	Kesesuaian format input	Seluruh gambar berhasil diproses menjadi format
T02	Pengujian restrukturisasi kelas	Kelas angry, disgust, fear, sad → stress; happy,	Jumlah kelas output	Dataset berhasil menjadi 2 kelas, yaitu stress dan
T03	Pengujian data leakage	Data train dan validation	Jumlah data duplikat	Tidak terdapat data duplikat antara train dan validation
T04	Pengujian baseline model CNN FP32	Model EmotionCNNDeepFC, data train dan validation	Accuracy, precision, recall, F1-score	Model baseline dapat dilatih dan mencapai target
T05	Pengujian ROC-AUC dan confusion matrix	Hasil prediksi pada data validation	ROC-AUC, confusion matrix	ROC curve, AUC, dan confusion matrix berhasil
T06	Pengujian FP16 half precision	Model CNN varian FP16 pada GPU	Ukuran model, accuracy, latency	FP16 dapat diuji dan dibandingkan dengan FP32
T07	Pengujian QINT8 dynamic quantization	Model CNN varian QINT8 pada CPU	Ukuran model, accuracy, latency	QINT8 dapat diuji dan dibandingkan dengan FP32
T08	Pengujian dashboard realtime	Upload gambar dan webcam realtime	Latency, hasil prediksi, confidence score, uji	Dashboard dapat menampilkan prediksi

DATASET FER2013

Dataset yang Digunakan

- Dataset: FER2013
- Sumber: Kaggle
- Jenis data: citra wajah grayscale
- Ukuran gambar: 48×48 piksel
- Digunakan untuk facial emotion recognition

Karakteristik Dataset

- Format grayscale
- Resolusi kecil untuk efisiensi komputasi
- Digunakan luas pada penelitian CNN
- Cocok untuk klasifikasi ekspresi wajah

7 Kelas Emosi Awal

- Angry
- Disgust
- Fear
- Happy
- Sad
- Surprise
- Neutral

RESTRUKTURISASI DATASET

STRES	NON STRES
Angry	Happy
Fear	Suprise
Sad	Neutral
Disgust	


Dibuat menjadi binary classification

DISTRIBUSI DATASET

Split	Stress	Non-Stress
Train	13.470	15.351
Validation	3.228	3.838

Total dataset:

- 28.821 train images
- 7.066 validation images



Sample Training Images After Augmentation

non_stress



stress




stress



non_stress



stress



non_stress




non_stress



non_stress





DATA CLEANING & PREPROCESSING

Data Cleaning

Dilakukan pengecekan duplicate dan overlap antara train dan validation untuk mencegah data leakage.

Metode cleaning:


- hashing gambar menggunakan MD5
- pengecekan duplicate
- pengecekan overlap train-validation

Tujuan:

agar evaluasi model lebih valid dan tidak terjadi kebocoran data.

Preprocessing

- grayscale 1 channel
- resize 48x48
- normalize mean dan std



DATA LEAKAGE PREVENTION

Apa itu Data Leakage?

Data leakage terjadi ketika data train dan validation memiliki gambar yang sama atau sangat mirip sehingga model hanya menghafal data, bukan benar-benar belajar pola.

Pencegahan yang Dilakukan

- Duplicate image checking
- Hashing menggunakan MD5
- Pemisahan train dan validation set

Dampak Jika Leakage Terjadi

- Accuracy terlihat tinggi
- Model tidak benar-benar belajar
- Performa deployment menurun pada data baru

AUGMENTATION

Data Augmentation

Data augmentation digunakan untuk menambah variasi data training agar model lebih mampu melakukan generalisasi dan mengurangi overfitting.

Augmentation yang dilakukan :

- random horizontal flip
- random rotation 15°
- random affine
- scaling

Tujuan augmentasi:

memperbanyak variasi data
mengurangi overfitting.

Data Augmentation — "non_stress"

Original




Aug 1



Aug 2



Aug 3



Aug 4




Aug 5



Aug 6



Aug 7



Aug 8



Aug 9



CONVOLUTIONAL NEURAL NETWORK (CNN)

Convolutional Neural Network (CNN) merupakan metode deep learning yang digunakan untuk pengolahan citra dan image classification. CNN bekerja dengan mengekstraksi fitur penting dari gambar melalui convolution layer, kemudian melakukan klasifikasi menggunakan fully connected layer. Pada proyek ini CNN digunakan untuk mengenali pola ekspresi wajah dan mengklasifikasikan gambar menjadi stress atau non_stress.

ARSITEKTUR MODEL CNN

Arsitektur EmotionCNNDeepFC Feature Extraction

Block 1:

- Conv2D 1→64
- BatchNorm
- ReLU
- MaxPooling
- Dropout

Block 2:

- Conv2D 64→128
- BatchNorm
- ReLU
- MaxPooling
- Dropout

Block 3:

- Conv2D 128→256
- BatchNorm
- ReLU
- MaxPooling
- Dropout

Classifier

Flatten:

$256 \times 6 \times 6 = 9216$ fitur

Fully Connected:

- 1024
- 512
- 256
- 128
- Output 2 kelas

Fungsi Komponen

- Conv2D → ekstraksi fitur wajah
- Pooling → reduksi dimensi
- Dropout → regularisasi
- Fully Connected → klasifikasi akhir

DETAIL MODEL CNN

Layer	Output Shape	Fungsi
Input	1×48×48	grayscale image
Conv Block 1	32×48×48	feature extraction
MaxPool	32×24×24	downsampling
Conv Block 2	64×24×24	deeper feature
MaxPool	64×12×12	reduce dimension
Conv Block 3	128×12×12	complex feature
MaxPool	128×6×6	compact feature
Flatten	4608	vectorization
FC Layer	256	classification feature
Output	2	stress/non-stress


KONFIGURASI TRAINING

Parameter	Nilai
Epoch	80
Batch Size	64
Optimizer	AdamW
Learning Rate	0.001
Weight Decay	0.0001
Loss Function	CrossEntropyLoss
Label Smoothing	0.1
Scheduler	ReduceLROnPlateau
Device	CUDA

Strategi Training

- early stopping
- best model saving
- scheduler learning rate
- dropout regularization

TRAINING PROCESS



HASIL TRAINING

Metrik	Nilai
Final Train Accuracy	85.13%
Validation Accuracy	84.00%
Weighted F1-Score	0.84
Validation Loss	0.43

Model menunjukkan peningkatan performa yang stabil selama proses training. Final train accuracy mencapai sekitar 85%, sedangkan validation accuracy mencapai 84%, sehingga selisih keduanya tidak terlalu besar dan overfitting tidak terlalu dominan. Validation loss berada pada kisaran 0.43 yang menunjukkan model sudah cukup stabil dalam melakukan klasifikasi stress dan non_stress.

KOMPLEKSITAS MODEL CNN

Komponen	Nilai
Total Parameters	11,277,122
Trainable Parameters	11,277,122
Jenis Model	Custom CNN
Output	Stress / Non-Stress

Correct Predictions

T: non_stress
P: non_stress
C: 0.95



T: non_stress
P: non_stress
C: 0.88




T: non_stress
P: non_stress
C: 0.93



T: non_stress
P: non_stress
C: 0.87



T: non_stress
P: non_stress
C: 0.95




T: non_stress
P: non_stress
C: 0.95



T: non_stress
P: non_stress
C: 0.96



T: non_stress
P: non_stress
C: 0.81




Wrong Predictions


T: non_stress
P: stress
C: 0.69




T: non_stress
P: stress
C: 0.69



T: non_stress
P: stress
C: 0.64




T: non_stress
P: stress
C: 0.78




T: non_stress
P: stress
C: 0.62




T: non_stress
P: stress
C: 0.89



T: non_stress
P: stress
C: 0.70



T: non_stress
P: stress
C: 0.70



CONFUSION MATRIX

Actual / Prediction	non_stress	stress
non_stress	3293	545
stress	522	2706

INTERPRETASI:

Correct Prediction

- 3293 non_stress dikenali benar
- 2706 stress dikenali benar

False Alarm

- 545 non_stress diprediksi sebagai stress

Missed Stress

- 522 stress gagal dikenali

INSIGHT

Kesalahan false alarm dan missed stress relatif seimbang.

Recall kelas stress masih perlu ditingkatkan untuk deployment nyata.

ROC CURVE & AUC

ROC Curve

ROC Curve digunakan untuk mengevaluasi kemampuan model dalam membedakan kelas stress dan non_stress pada berbagai threshold klasifikasi.


AUC (Area Under Curve)

AUC menunjukkan kualitas performa model secara keseluruhan.

- Nilai mendekati 1 → model sangat baik
- Nilai mendekati 0.5 → model kurang baik

Hasil Evaluasi

- ROC Curve menunjukkan performa klasifikasi yang baik
- Model mampu membedakan stress dan non_stress dengan cukup stabil
- AUC Score tinggi menunjukkan kemampuan klasifikasi yang baik



ROC-AUC SCORE: 0.9264

CLASSIFICATION REPORT

Kelas	Precision	Recall	F1-Score	Support
non_stress	0.86	0.86	0.86	3838
stress	0.83	0.84	0.84	3228
weighted avg	0.85	0.85	0.85	7066
Macro Avg	0.84	0.84	0.85	7066

Model memperoleh accuracy sebesar 84% dengan weighted F1-score sebesar 0.84. Recall kelas stress sebesar 0.83 menunjukkan sebagian besar citra stress berhasil dikenali oleh model.

Secara umum performa model cukup stabil dan seimbang pada kedua kelas.

QUANTIZATION

Quantization Model


Quantization digunakan untuk mengoptimasi model agar lebih ringan dan cepat.

Tujuan Quantization



- mengurangi ukuran model
- mempercepat inferensi
- mengurangi penggunaan memori
- mendukung deployment realtime

ALASAN

- layer Linear memiliki parameter terbesar
- penggunaan memori lebih tinggi
- paling efektif untuk pengurangan ukuran model



PRECISION FORMAT



Format	Bit	Variant
FP32	32-bit	REAL
FP16	16-bit	REAL
QINT8	8-bit	REAL
FP8	8-bit	SIMULATED
FP4	4-bit	SIMULATED
QINT4	4-bit	SIMULATED



QUANTIZATION

JENIS JENIS QUANTIZATION

Jenis Quantization	Keterangann
FP16	Menggunakan representasi 16-bit floating point.
QINT8 Dynamic Quantization	Menggunakan integer 8-bit pada layer Linear.
Bagian Model yang Di-Quantize	Dynamic quantization diterapkan pada layer Fully Connected (nn.Linear).

Quantization Model

Quantization digunakan untuk mengoptimasi model agar lebih ringan dan cepat.

Tujuan Quantization

- mengurangi ukuran model
- mempercepat inferensi
- mengurangi penggunaan memori
- mendukung deployment realtime

ALASAN

- layer Linear memiliki parameter terbesar
- penggunaan memori lebih tinggi
- paling efektif untuk pengurangan ukuran model

JENIS PRECISION & QUANTIZATION

FP32 Baseline

FP32 digunakan sebagai baseline utama pada proyek ini karena menggunakan full precision 32-bit sehingga performa model lebih stabil dan akurat. Namun penggunaan precision penuh menyebabkan ukuran model menjadi lebih besar dan inferensi membutuhkan komputasi yang lebih tinggi.

FP16

FP16 menggunakan half precision inference dengan representasi floating point 16-bit untuk mengurangi ukuran model dan mempercepat inferensi pada GPU. Hasil pengujian menunjukkan bahwa FP16 memiliki latency lebih cepat dengan penurunan akurasi yang kecil dibanding FP32. Namun FP16 bukan quantization penuh karena masih menggunakan floating point, hanya jumlah bit-nya yang dikurangi dari 32-bit menjadi 16-bit.

JENIS PRECISION & QUANTIZATION

QINT8

QINT8 menggunakan dynamic quantization melalui `torch.nn.quantization.quantize_dynamic` untuk mengurangi ukuran model dan membuat inferensi CPU menjadi lebih ringan. Pada proyek ini quantization diterapkan pada layer `nn.Linear`, sedangkan convolution layer belum diquantize penuh. QINT8 cocok digunakan untuk deployment pada perangkat dengan resource terbatas.

FLOAT8 / FLOAT4 / QINT4

FLOAT8, FLOAT4, dan QINT4 digunakan sebagai simulasi low-bit analysis untuk melihat potensi kompresi model pada precision yang lebih kecil. Eksperimen FP8 native sempat dicoba, namun inference gagal karena backend CUDA/cuDNN belum mendukung penuh operasi FP8 pada CNN, ditunjukkan oleh error `getCudnnDataTypeFromScalarType() not supported`. Oleh karena itu low-bit variant pada proyek ini masih berupa simulasi dan belum digunakan sebagai quantization nyata.

PERBANDINGAN MODEL

MODEL	ACCURACY	UKURAN	LATENCY
FP32	Tinggi	Besar	Lebih Lambat
FP16	Hampir Sama	Kecil	Cepat
QINT8	Turun Sedikit	Paling kecil	Ringan

Interpretasi

FP32

Merupakan model baseline dengan presisi penuh sehingga memiliki akurasi paling stabil, namun ukuran model lebih besar dan latency inferensi lebih lambat.

FP16

Menggunakan presisi 16-bit sehingga ukuran model lebih kecil dan inferensi lebih cepat, terutama pada GPU, dengan penurunan akurasi yang sangat kecil.

QINT8

Menggunakan representasi integer 8-bit sehingga ukuran model menjadi paling ringan dan efisien untuk deployment CPU atau embedded device, meskipun terdapat sedikit penurunan akurasi.

HASIL QUANTIZATION

MODEL	ACCURACY	UKURAN	LATENCY
FP32	0.8365	Besar	Relatif Lebih Lambat
FP16	0.8363	Kecil	Cepat
QINT8	0.8361	Paling kecil	Ringan

Interpretasi Hasil Quantization

FP32

Merupakan model baseline dengan presisi penuh sehingga memiliki akurasi paling stabil, namun ukuran model lebih besar dan inferensi membutuhkan komputasi yang lebih tinggi.


FP16

Menggunakan half precision 16-bit sehingga ukuran model menjadi lebih kecil dan inferensi pada GPU berjalan lebih cepat, dengan penurunan akurasi yang sangat kecil dibanding FP32.

QINT8

Menggunakan dynamic quantization dengan representasi integer 8-bit pada layer linear sehingga ukuran model menjadi lebih ringan dan lebih efisien untuk deployment CPU atau perangkat dengan resource terbatas.

HASIL QUANTIZATION



SIMULATED LOW-BIT PRECISION

Variant	Accuracy	Size	Latency	Status
FLOAT8	~FP32	Lebih kecil	~FP32	Simulated
FLOAT4	~FP32	Sangat kecil	~FP32	Simulated
QINT4	~FP32	Paling kecil	~FP32	Simulated


FLOAT8 / FLOAT4 / QINT4

Merupakan simulasi low-bit precision yang digunakan untuk menganalisis potensi pengurangan ukuran model pada deployment masa depan. Implementasi native low-bit quantization belum stabil pada hardware yang digunakan sehingga varian ini belum diterapkan sebagai quantization nyata.


Accuracy dan latency pada FLOAT8, FLOAT4, dan QINT4 masih menggunakan fallback FP32 sehingga hasil evaluasi hanya bersifat estimasi dan bukan performa asli low-bit inference.

***Estimasi berdasarkan fallback FP32**

Estimated Compression Ratio Compared to FP32 Baseline



Simulated Low-Bit Model Size



IMPLEMENTASI DASHBOARD SISTEM MULTIMEDIA

Fitur Dashboard

1. Upload Image

Pengguna dapat mengunggah foto wajah untuk dilakukan klasifikasi stress atau non_stress.

2. Realtime Webcam

Sistem dapat mengambil gambar langsung dari kamera/webcam untuk deteksi realtime.

3. CNN Inference

Citra wajah akan diproses menggunakan preprocessing dan model CNN untuk menghasilkan prediksi.

4. Hasil Klasifikasi

Dashboard menampilkan hasil:

- stress / non_stress
- confidence prediction
- status deteksi realtime


5. Visual Analytics

Dashboard dapat menampilkan:

- confidence score
- grafik emosi
- hasil prediksi visual
- monitoring realtime



KESIMPULAN



Berdasarkan hasil eksperimen, model CNN berhasil digunakan untuk klasifikasi stress dan non_stress dari citra ekspresi wajah dengan validation accuracy sebesar 84%. Dataset juga telah dibersihkan untuk mencegah data leakage sehingga evaluasi model lebih valid. Selain itu, optimasi FP16 dan QINT8 mampu mengurangi ukuran model dan latency inferensi dengan penurunan akurasi yang relatif kecil. FP16 lebih cocok untuk deployment GPU realtime, sedangkan QINT8 cocok untuk deployment CPU ringan.

STRUKTUR PERAN TIM

Anggota	Peran	Tanggung jawab utama	Deliverable	% kontribusi (estimasi)
Fitri	Koordinator Proyek dan Deep Learning	Mengkoordinasikan alur kerja tim, membantu perancangan model CNN, menyusun bagian metodologi, serta membantu integrasi	Koordinasi proyek, rancangan model CNN, metodologi, integrasi sistem	25%
Kanaya	Data Preparation dan Quantization	Menangani restrukturisasi dataset FER2013 menjadi kelas stress dan non_stress, melakukan preprocessing, augmentasi, pengecekan	Dataset siap training, preprocessing pipeline, hasil eksperimen quantization	25%
Nashwa	Evaluasi Model dan Analisis Hasil	Melakukan evaluasi model menggunakan accuracy, precision, recall, F1-score, confusion matrix, ROC-	Hasil evaluasi model, confusion matrix, ROC-AUC, grafik dan tabel perbandingan	25%
Amel	Sistem Multimedia dan Dashboard Realtime	Merancang dan mengembangkan dashboard realtime, termasuk fitur upload gambar, webcam,	Prototype dashboard realtime, fitur upload gambar, fitur webcam, tampilan output prediksi	25%

WBS



No	Paket kerja	Output	PIC	Waktu (minggu)	Bukti (repo/log)
1	Studi literatur CNN, FER2013, quantization, dan	Ringkasan teori dan referensi proyek	Semua anggota	Minggu 1	Dokumen studi literatur / catatan referensi
2	Pengumpulan dan pemeriksaan struktur dataset FER2013	Dataset tersedia dengan folder train dan validation	Kanaya	Minggu 2	Log pengecekan dataset / screenshot struktur folder
3	Restrukturisasi dataset menjadi kelas stress dan non-stress	Dataset dua kelas siap digunakan	Kanaya	Minggu 2-3	Notebook preprocessing / log jumlah data tiap
4	Preprocessing dan augmentasi citra	Pipeline grayscale, resize 48x48, normalisasi, dan	Kanaya	Minggu 3	Notebook transformasi data / kode preprocessing
5	Perancangan dan implementasi model CNN	Arsitektur model CNN untuk klasifikasi stress dan non-stress	Fitri	Minggu 4	Kode model CNN / commit repository
6	Training baseline model FP32	Model baseline FP32 terlatih	Fitri	Minggu 5-6	Notebook training / file model tersimpan
7	Evaluasi model baseline	Classification report, confusion matrix, ROC AUC, dan grafik	Nashwa	Minggu 6-7	Notebook evaluasi / gambar visualisasi hasil
8	Eksperimen precision dan quantization	Perbandingan FP32, FP16, QINT8, serta simulasi	Nashwa & Kanaya	Minggu 8-9	Notebook quantization / tabel perbandingan model
9	Perancangan dan implementasi dashboard realtime	Prototype dashboard dengan upload gambar, webcam,	Amel	Minggu 10-12	Kode dashboard / screenshot tampilan dashboard
10	Integrasi sistem, pengujian akhir, laporan dan	Sistem terintegrasi, hasil uji, laporan akhir, dan slide	Semua anggota	Minggu 13-14	Laporan akhir / slide / demo dashboard

JADWAL PENGERJAAN



Minggu	Aktivitas utama	Output
1	Studi literatur mengenai CNN, FER2013, facial expression recognition, precision, quantization, dan	Ringkasan teori dan referensi awal proyek
2	Definisi masalah, rumusan kebutuhan sistem, dan penyusunan rancangan solusi	Rumusan masalah, tujuan, batasan, dan rancangan awal sistem
3	Pengumpulan dataset FER2013 dan pemeriksaan struktur folder train dan validation	Dataset tersedia dan struktur data teridentifikasi
4	Restrukturisasi dataset dari 7 kelas emosi menjadi 2 kelas yaitu stress dan non stress	Dataset dua kelas siap digunakan
5	Preprocessing dan augmentasi citra, termasuk grayscale, resize 48×48, normalisasi, dan augmentasi	Pipeline preprocessing dan augmentasi data
6	Perancangan arsitektur model CNN EmotionCNNDeenEC	Struktur model CNN dan kode awal model
7	Implementasi baseline model CNN menggunakan FP32	Model baseline FP32 dapat dijalankan
8	Training model CNN dan pemantauan performa validation	Model CNN terlatih dan catatan training
9	Evaluasi model menggunakan accuracy, precision, recall, F1-score, confusion matrix, dan ROC-AUC	Hasil evaluasi model dan visualisasi metrik
10	Implementasi eksperimen FP16 dan QINT8	Varian model FP16 dan QINT8 siap dibandingkan
11	Simulasi FLOAT8, FLOAT4, QINT4 serta analisis perbandingan accuracy, ukuran model, dan latency	Tabel dan grafik perbandingan model
12	Perancangan dan implementasi dashboard realtime berbasis upload gambar dan webcam	Prototype dashboard realtime
13	Integrasi model CNN ke dashboard, pengujian upload gambar, webcam, confidence score, dan output visual	Sistem terintegrasi dan hasil pengujian dashboard
14	Penyusunan laporan akhir, slide presentasi, dokumentasi, dan persiapan demo	Laporan akhir, slide presentasi, dan demo dashboard

MITIGASI RISIKO

Risiko	Dampak	Mitigasi	PIC
Dataset memiliki kualitas gambar yang beragam, seperti blur, pencahayaan kurang baik, atau masih banyak noise	Model sulit mengenali pola ekspresi wajah dengan baik	Melakukan preprocessing berupa grayscale, resize, normalisasi, serta augmentasi dataset agar model lebih robust	Kanaya
Terjadi data leakage antara data train dan validation	Evaluasi model menjadi tidak valid karena model dapat mengenali data yang sudah pernah dilihat	Melakukan pengecekan duplikat antara train dan validation, serta menggunakan hashing MD5 jika diperlukan	Kanaya
Model mengalami overfitting pada data training	Performa model bagus pada training tetapi menurun pada validation	Menggunakan data augmentation, dropout, regularisasi, scheduler, dan early stopping	Fitri
Hasil accuracy belum mencapai target minimal	Model belum cukup baik untuk klasifikasi stress dan non_stress	Melakukan tuning hyperparameter, menyesuaikan arsitektur CNN, dan memodifikasi layer	Fitri & Nashwa
Eksperimen FP16 atau QINT8 tidak berjalan stabil pada perangkat tertentu	Perbandingan precision dan quantization tidak lengkap	Menggunakan FP32 sebagai baseline utama, menjalankan FP16 pada GPU, QINT8 pada CPU, serta memodifikasi layer	Kanaya
Dashboard realtime mengalami error saat membaca upload gambar atau webcam	Sistem multimedia tidak dapat berjalan sesuai rancangan	Membuat fitur secara bertahap, dimulai dari upload gambar, lalu webcam; menyediakan fallback upload gambar jika webcam	Amel



**TERIMA
KASIH**



LAMPIRAN

DAFTAR ISI

Latar Belakang

Rumusan Masalah

Tujuan Proyek

Landasan Teori

Dataset

**Data Cleaning &
Preprocessing**

Metodologi Penelitian

Arsitektur Model CNN

Konfigurasi Training

Hasil Training

Validation Result

Confusion Matrix

Quantization

Perbandingan Model

**IMPLEMENTASI DASHBOARD
SISTEM MULTIMEDIA**

Kesimpulan

BATASAN & ASUMSI

Tahapan	Aktivitas Utama	Output / Hasil
1. Studi Literatur	Studi teori CNN & identifikasi masalah	Rumusan masalah & Pemilihan dataset FER2013
2. Perancangan	Resizing 48x48 grayscale & grouping kelas biner	Desain arsitektur Custom CNN & skenario kuantisasi
3. Baseline	Training model dengan presisi FP32	Model acuan (baseline) klasifikasi biner
4. Optimasi	Pengujian FP16, QINT8, dan simulasi low-bit (FLOAT4/8)	Variasi model yang terkompresi
5. Evaluasi	Komparasi metrik akurasi, ukuran file, dan latency	Data performa terbaik (sweet spot model)
6. Dokumentasi	Penyusunan laporan & pembuatan sistem realtime	Dashboard prototype (Webcam & Upload foto)

LANDASAN TEORI

CONVOLUTIONAL NEURAL NETWORK (CNN)

CNN digunakan untuk mengekstraksi fitur visual dari citra wajah melalui convolution layer, pooling, dan fully connected layer.

QUANTIZATION

Quantization merupakan teknik optimasi model dengan mengubah representasi angka presisi tinggi menjadi presisi lebih rendah, seperti FP32 menjadi INT8 atau FP16.

Tujuan quantization:

- mengurangi ukuran model
- mempercepat inferensi
- menurunkan penggunaan memori